Introducción a la Ciencia de Datos · Sociedad

Felicidad y bienestar



Camila Barboza, Belén Etchegoimberry, Candelaria Facello y Clara Gimenez

Comienzo del código en Visual Studio

```python
from pathlib import Path

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import plotly.express as px # gráficos interactivos
import plotly.io as pio # configura dnde ver gráficos interactivos
import pycountry_convert as pc # convierte nombre pais a continente
import statsmodels.api as sm # regresión lineal (R², R² ajustado y coeficientes)

# Rutas
BASE_DIR = Path(__file__).resolve().parent
DATA_DIR = BASE_DIR.parent / "data"
GRAF_DIR = BASE_DIR.parent / "graficos"
```

1. **Librerías que importamos.**

- Path (de pathlib): trabajar con rutas de carpetas y archivos.
- pandas: leer y manipular las bases de datos.
- numpy: cálculos numéricos.
- matplotlib.pyplot: crear los gráficos estáticos (dispersión, barras).
- plotly.express: crear gráficos interactivos, como el mapa por regiones.
- plotly.io: configurar dónde se abren los gráficos interactivos (por ejemplo, en el navegador).
- pycountry_convert: convertir el nombre de cada país en su continente.
- statsmodels.api: hacer las regresiones lineales y obtener R^2, R^2 ajustado y coeficientes.

```python
# 1.1 CARGA Y PRIMERA VISTA DATOS FELICIDAD
# Ruta dataset del World Happiness Report
ruta_csv_happiness = DATA_DIR / "world_happiness_Update_report_2026.csv"

# Verificar que el archivo realmente existe antes de cargarlo
if not ruta_csv_happiness.exists():
    raise FileNotFoundError(f"No se encontró el archivo en: {ruta_csv_happiness}")

# Cargar el archivo CSV
df_happiness = pd.read_csv(ruta_csv_happiness)
```

2. **Cargamos el dataset de Felicidad - World Happiness Report 2026**

Cotiene: Puntaje de felicidad y seis variables: PIB per cápita, apoyo social, esperanza de vida saludable, libertad, generosidad y corrupción.

1. Nombramos la ruta.
2. Verificamos si el archivo realmente existe.
3. Lo cargamos.

Limpieza de datos

```python
# 1.2 LIMPIEZA: países duplicados
print("Filas:", len(df_happiness))
print("Países únicos:", df_happiness["country"].nunique())
print("Filas repetidas por país:", df_happiness["country"].duplicated().sum())

# Miramos duplicados
duplicados = df_happiness[df_happiness["country"].duplicated(keep=False)]
print(duplicados.sort_values("country").to_string())

# Decisión: promediar las filas repetidas de cada país.
df_happiness_limpio = (
    df_happiness.drop(columns="rank") # El ranking no se promedia
    .groupby("country", as_index=False)
    .mean(numeric_only=True)
)
```

El resultado, df_happiness_limpio, tiene una fila por país, con el promedio de cada variable. Esto es necesario para poder unir después este dataset con el de salud mental sin que se dupliquen filas.

```python
# 1.3 RENOMBRAR COLUMNAS AL ESPAÑOL
NOMBRES_ES_WH = {
    "country": "País",
    "gdp_per_capita": "PIB per cápita",
    "social_support": "Apoyo social",
    "healthy_life_expectancy": "Esperanza de vida saludable",
    "freedom": "Libertad",
    "generosity": "Generosidad",
    "corruption": "Percepción de corrupción",
    "score": "Puntaje de felicidad",
}
df_happiness_limpio = df_happiness_limpio.rename(columns=NOMBRES_ES_WH)
```

3. **Limpiamos el dataset de felicidad.**

1. Detectar el problema
   - len(df_happiness) cuenta las filas totales.
   - ["country"].nunique() cuenta los países únicos.
   - ["country"].duplicated().sum() cuenta cuántas filas están repetidas.
2. Miramos los duplicados
   - duplicated(keep=False) marca todas las filas de los países repetidos.
   - sort_values("country") las ordena por país, así las filas del mismo país quedan juntas.
   - .to_string() imprime la tabla completa, sin que pandas la abrevie.
3. La decisión: promediar
   - drop(columns="rank") saca el ranking antes de promediar, porque promediar posiciones no tiene sentido.
   - groupby("country", as_index=False) agrupa las filas del mismo país. as_index=False deja el país como columna normal y no como índice.
   - .mean(numeric_only=True) calcula el promedio de las columnas numéricas de cada grupo.

Renombramiento.

Acá se renombran las columnas del dataset de felicidad del inglés al español.

- Cada par es "nombre original": "nombre nuevo"
- .rename(columns=NOMBRES_ES_WH) pandas busca cada columna por su nombre original y la reemplaza por el nuevo. Se guarda sobre df_happiness_limpio.

Correlaciones con el puntaje de felicidad

```python
datos = df[[PAIS, var_x, var_y]].dropna() # Quedarse solo con filas completas para x e y
x = datos[var_x]
y = datos[var_y]

# Correlación
corr = np.corrcoef(x, y)[0, 1]
```

Prepara los datos

- df[[PAIS, var_x, var_y]].dropna() se queda solo con las filas que tienen valor en ambas variables, para que el cálculo no falle por datos faltantes.
- var_y=PUNTAJE es el valor por defecto: el eje Y siempre es el puntaje de felicidad, y solo cambia la variable X.

Calcular la correlación

- np.corrcoef(x, y)[0, 1] calcula el coeficiente de Pearson, que va de −1 a 1. Mide qué tan alineados están los puntos en una recta.

```python
# Países atípicos: mayor distancia vertical a la recta
if n_atipicos > 0:
    residuos = y - recta(x)
    idx_atipicos = residuos.abs().nlargest(n_atipicos).index
    atipicos = datos.loc[idx_atipicos]

    x_rango = x.max() - x.min()
    for _, pais in atipicos.iterrows():
        # Si está en la mitad derecha del gráfico, la etiqueta va a la izquierda
        a_la_derecha = pais[var_x] > x.min() + 0.7 * x_rango
        # Si el punto está por encima de la recta, etiqueta arriba; si no, abajo
        arriba = (pais[var_y] - recta(pais[var_x])) > 0
        dx = -8 if a_la_derecha else 8
        dy = 10 if arriba else -14
        ax.annotate(
            pais[PAIS],
            (pais[var_x], pais[var_y]),
            xytext=(dx, dy),
            textcoords='offset points',
            ha='right' if a_la_derecha else 'left',
            fontsize=8,
            arrowprops=dict(arrowstyle='-', color='gray', lw=0.5)
        )
```

Detectar países atípicos

- residuos = y - recta(x) es la distancia vertical entre cada país y la recta.
- .abs().nlargest(5) elige los 5 países más alejados de la recta.
- Después se etiquetan con annotate. La posición de la etiqueta (izquierda o derecha, arriba o abajo) se ajusta según dónde cae el punto, para que no se salga del gráfico ni tape otros puntos.

```python
    # Título representativo (los nombres de columna ya están en español)
    ax.set_title(f'{var_x} vs {var_y}', fontsize=13, fontweight='bold', pad=12)

    ax.set_xlabel(var_x, fontsize=10)
    ax.set_ylabel(var_y, fontsize=10)

    # Estética general
    ax.spines['top'].set_visible(False)
    ax.spines['right'].set_visible(False)
    ax.grid(alpha=0.2)

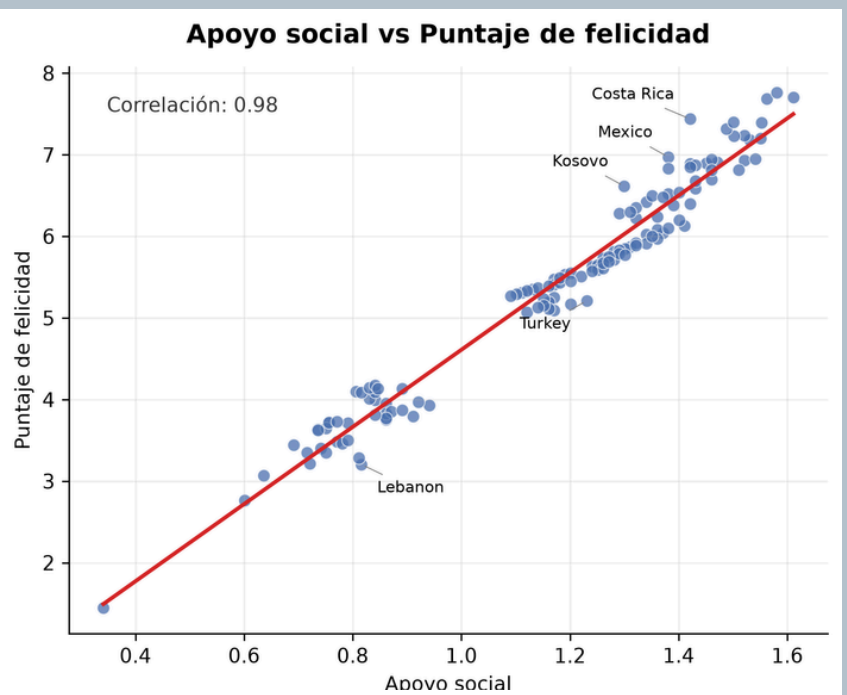
    plt.tight_layout()
    plt.savefig(GRAF_DIR/ f'correlacion_{archivo}.png', dpi=300, bbox_inches="tight")
    plt.close(fig)

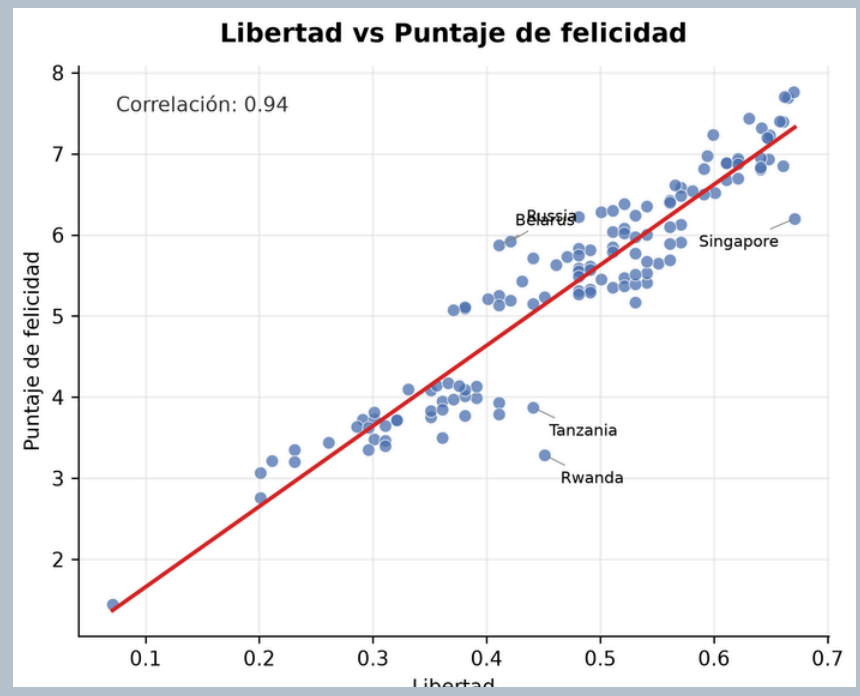
# Llamamos función correlaciones con variables de felicidad:
grafico_correlacion(df_happiness_limpio, 'PIB per cápita', 'pib')
grafico_correlacion(df_happiness_limpio, 'Apoyo social', 'apoyo_social')
grafico_correlacion(df_happiness_limpio, 'Esperanza de vida saludable','esperanza_vida')
grafico_correlacion(df_happiness_limpio, 'Libertad', 'libertad')
grafico_correlacion(df_happiness_limpio, 'Generosidad', 'generosidad')
grafico_correlacion(df_happiness_limpio, 'Percepción de corrupción', 'corrupción')
```

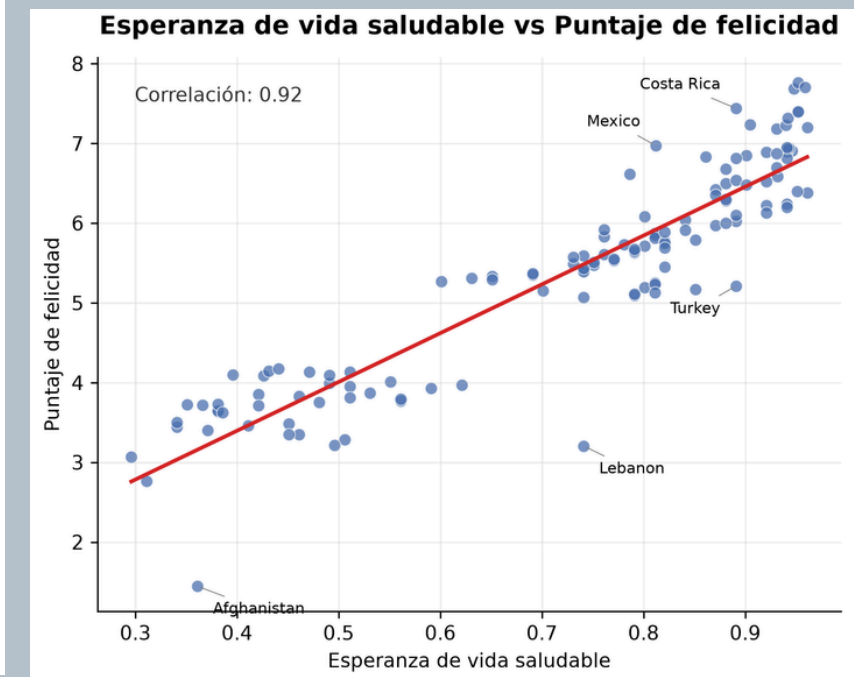
- Cada línea llama a grafico_correlacion con el dataset limpio, la variable del eje X y el nombre del archivo.
- Las variables son PIB per cápita, apoyo social, esperanza de vida saludable, libertad, generosidad y percepción de corrupción.
- Resultado: 6 imágenes en graficos, cada una con su recta de regresión, la correlación y los 5 países atípicos. No se muestra nada en pantalla, solo se guardan.

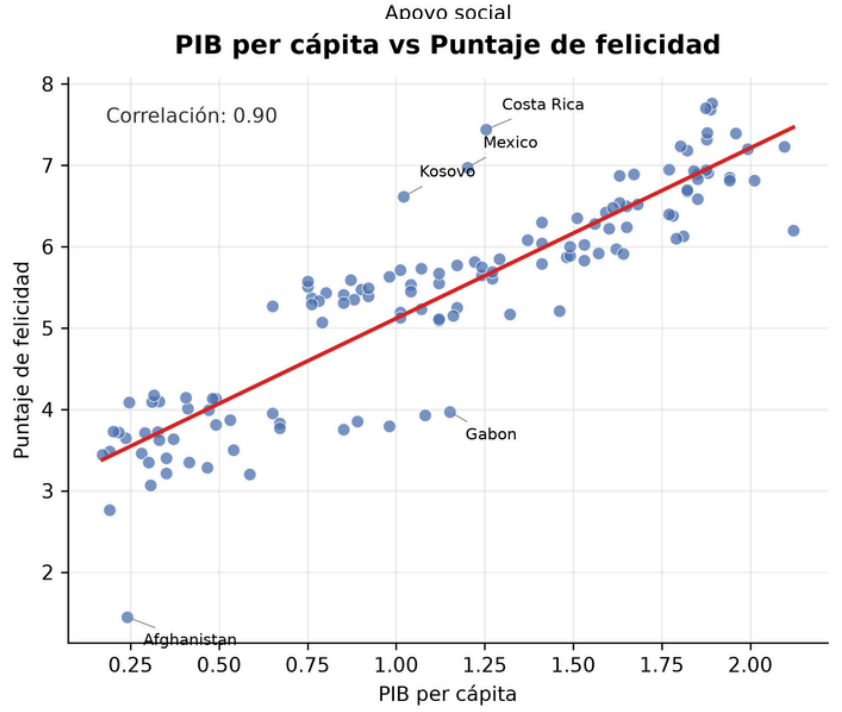
RESULTADO

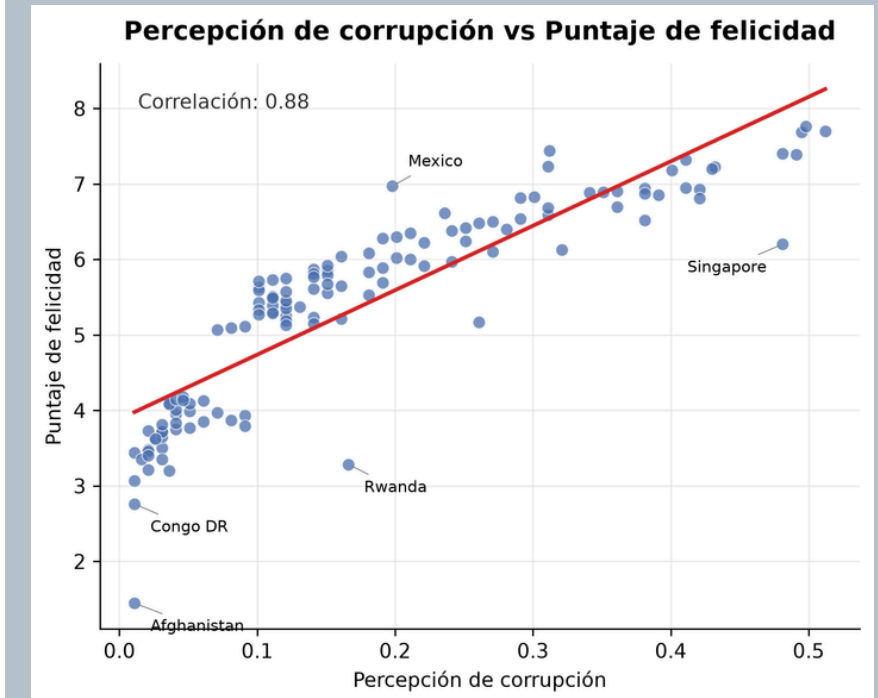
- Apoyo social (0,98): es la variable más asociada al puntaje.
- Libertad (0,94),
- Esperanza de vida saludable (0,92),
- PIB per cápita (0,90)
- Percepción de corrupción (0,88): también tienen correlaciones muy altas.
- Generosidad (0,25): es la única débil, así que casi no ayuda a distinguir a los países más felices de los menos felices.

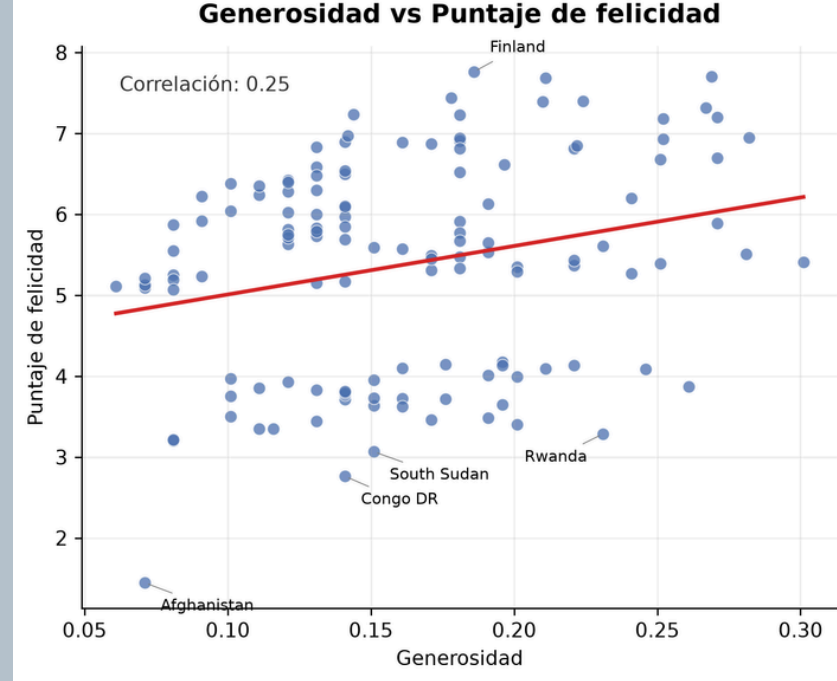












TABLA

```
# Tabla de puntaje de correlación de las variables
variables_whr = ["PIB per cápita", "Apoyo social", "Esperanza de vida saludable",
                 "Libertad", "Generosidad", "Percepción de corrupción"]

print("\n\nCORRELACIONES DE LAS VARIABLES DEL WHR CON EL PUNTAJE DE FELICIDAD:")
print(df_happiness_limpio[variables_whr + [PUNTAJE]].corr()[PUNTAJE].drop(PUNTAJE).round(2))

print("\nLas correlaciones son altas porque estas variables son con las que el WHR construye y explica el puntaje de felicidad.")
```

- variables_whr es la lista con los nombres de las 6 variables.
- .corr() calcula la correlación entre todas las columnas de la lista y el puntaje.
- [PUNTAJE].drop(PUNTAJE).round(2) se queda solo con la columna del puntaje, saca la correlación del puntaje consigo mismo (siempre 1) y redondea a 2 decimales.

```
CORRELACIONES DE LAS VARIABLES DEL WHR CON EL PUNTAJE DE FELICIDAD:
PIB per cápita                0.90
Apoyo social                  0.98
Esperanza de vida saludable   0.92
Libertad                      0.94
Generosidad                   0.25
Percepción de corrupción      0.88
Name: Puntaje de felicidad, dtype: float64

Las correlaciones son altas porque estas variables son con las que el WHR construye y explica el puntaje de felicidad.
```

Las correlaciones son tan altas porque el WHR construye el puntaje a partir de estas mismas variables. Por eso no es un hallazgo nuevo, y es la razón por la que después sumamos el dataset de salud mental.

DATASET SALUD MENTAL

Global_Mental_Health_Crisis_Index_2026.csv (24.35 kB)

Detail | Compact | Column

10 of 29 columns

country	iso3	region	income_gr...	# depressio...	# anxiety_pct
Malawi	MWI	Africa	Low	3.3	4.5
Mozambique	MOZ	Africa	Low	3.4	4.6
Ethiopia	ETH	Africa	Low	3.5	4.8
Zimbabwe	ZWE	Africa	Low	4.0	5.2
Tanzania	TZA	Africa	Low	3.6	4.9
Uganda	UGA	Africa	Low	3.5	4.8

Global Mental Health Crisis Index 2026

— Kaggle

Unión de DATASETS

```
# ============================================================
# UNIR DATASET DE FELICIDAD CON DATASET DE SALUD MENTAL
# ============================================================

# Ruta del dataset de salud mental
ruta_csv_mental = BASE_DIR.parent / "data" / "Global_Mental_Health_Crisis_Index_2026.csv"

# Verificar que el archivo existe
if not ruta_csv_mental.exists():
    raise FileNotFoundError(f"No se encontró el archivo en: {ruta_csv_mental}")

# Cargar el dataset de salud mental
mental = pd.read_csv(ruta_csv_mental)

print("\n--- Dataset de salud mental cargado ---")
print(mental.info()) # No hay valores nulos
print("\nPrimeras 5 filas:")
print(mental.head())
```

```
# Uno el dataset de felicidad con el de salud mental por pais
df_final = pd.merge(
    df_happiness_limpio,
    mental_limpio,
    on="country",
    how="inner" # para que no se repita la columna de pais
)

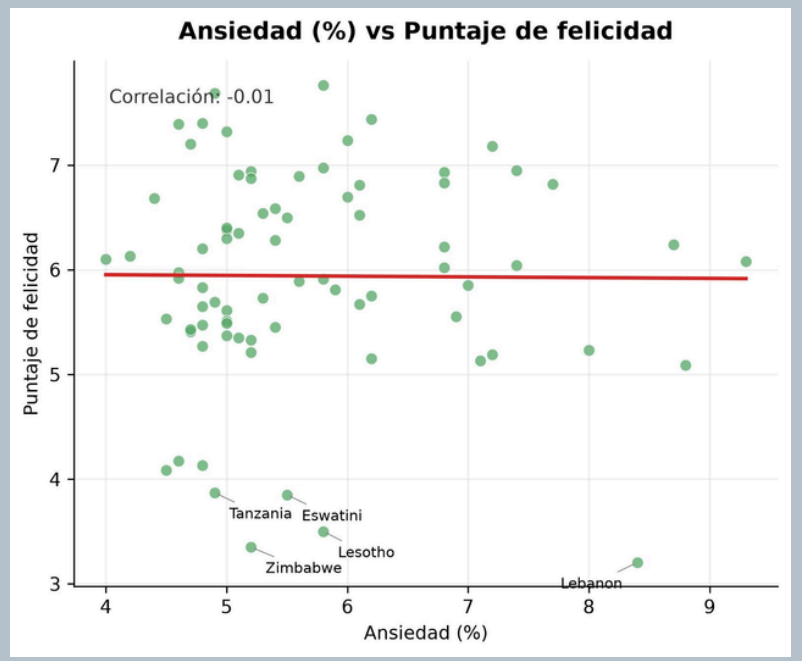
print("\n--- DataFrame final ---")
print(df_final.info())
df_final.shape

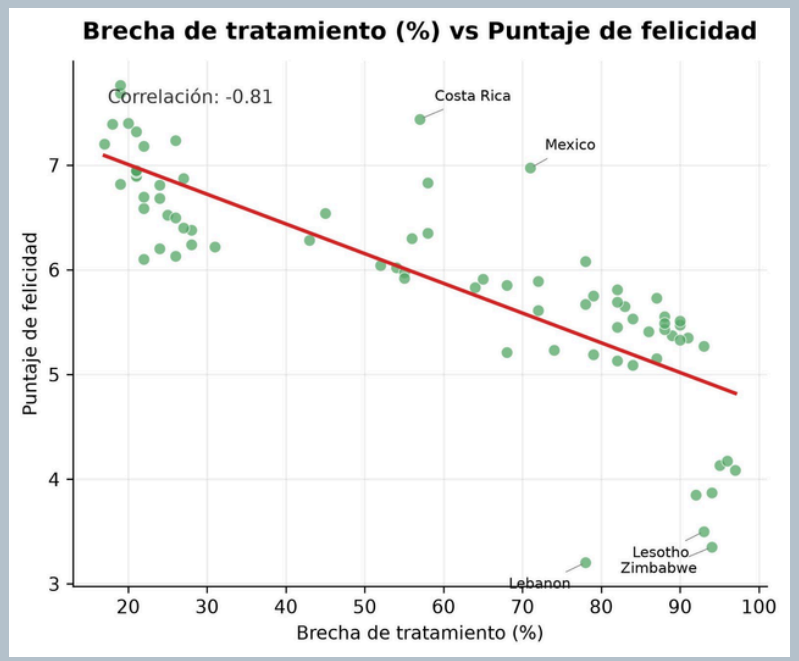
print("\nPrimeras 5 filas:")
print(df_final.head())

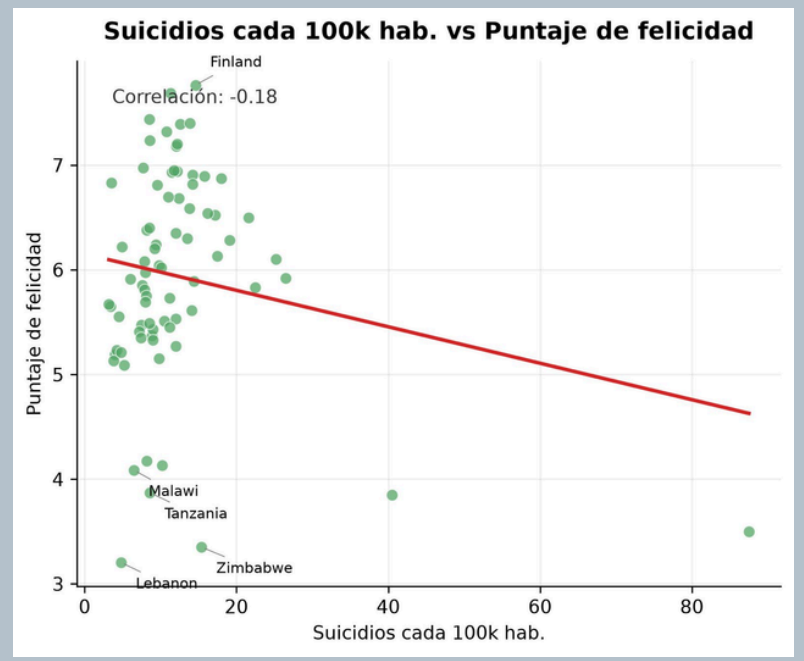
print("\nCantidad de países antes de unir:", len(df_happiness_limpio))
print("Cantidad de países después de unir:", len(df_final))

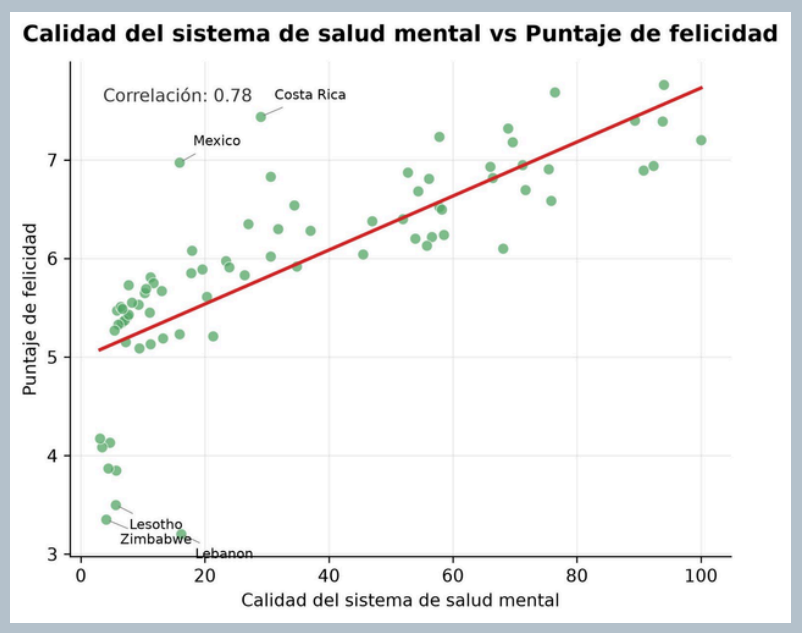
print("Filas totales:", len(df_final))
print("Países únicos:", df_final["country"].nunique())
print("Duplicados por país:", df_final["country"].duplicated().sum()) # Dataset limpio sin duplicados
print(df_final["country"].value_counts()[df_final["country"].value_counts() > 1])
```

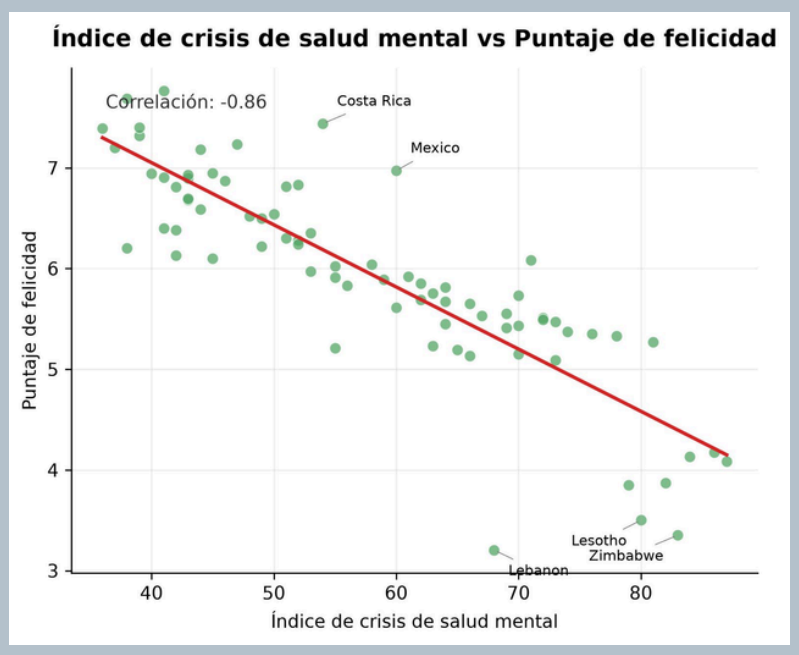
Correlaciones del dataset SALUD con FELICIDAD

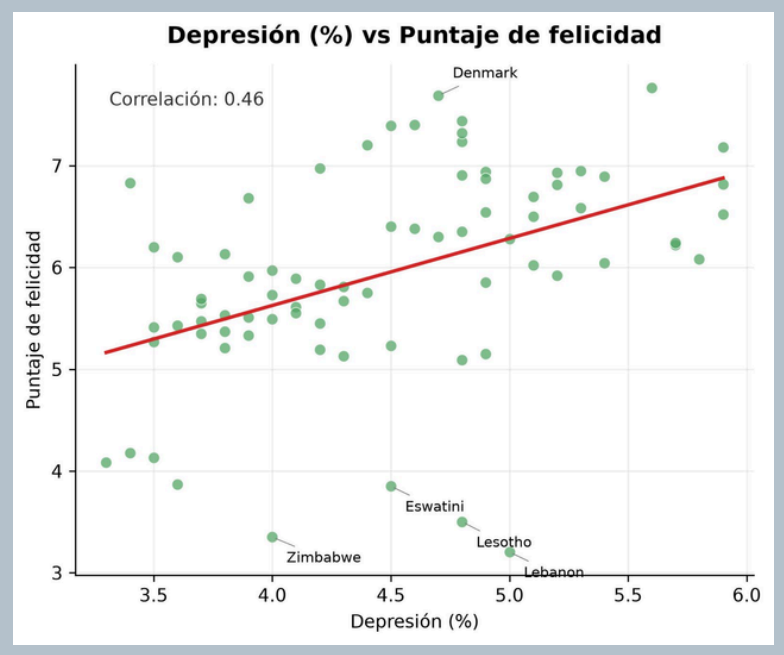












Exploración

1. **Resumen de las correlaciones de cada dataset**

Utilidad: Comparar y determinar cuales variables usar para los modelos de regresión lineal

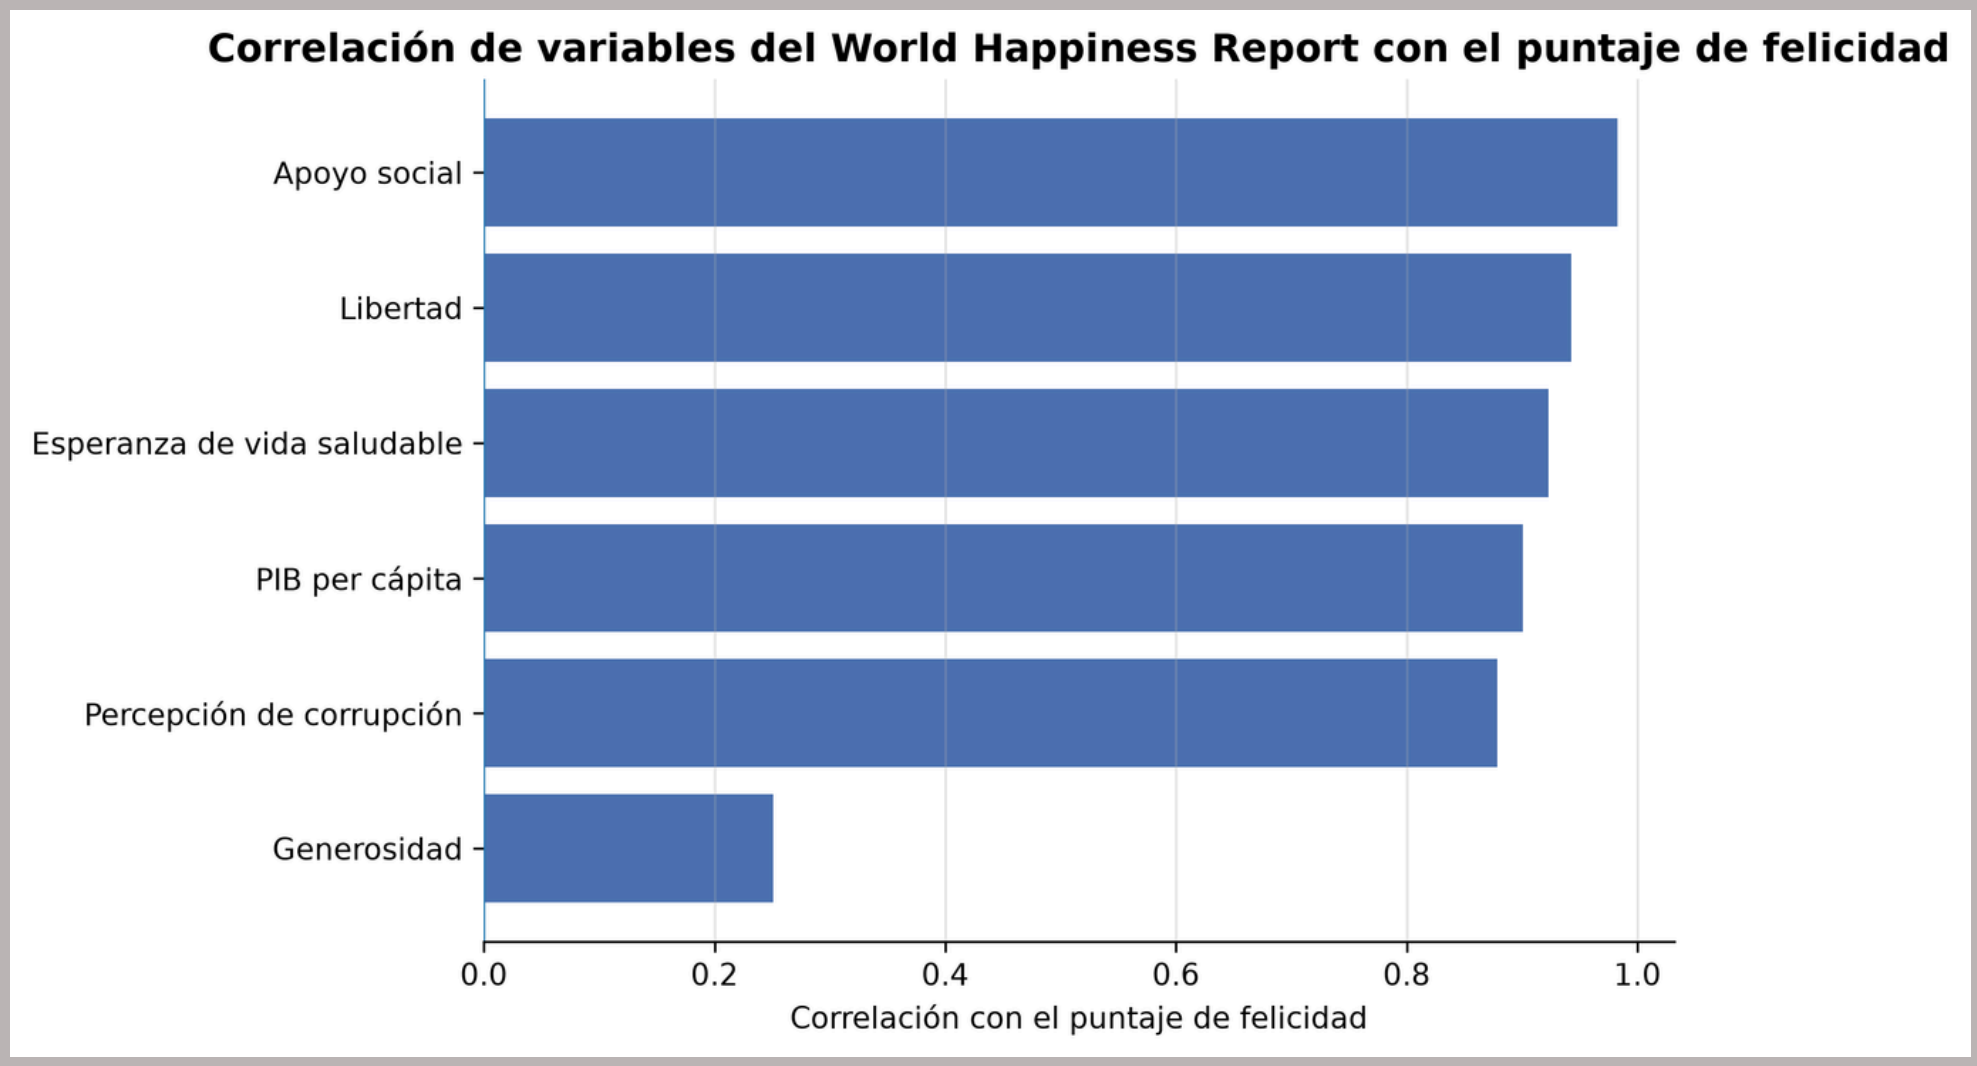
```python
# 3.1 BARRAS DE RESUMEN: correlación de cada variable con el puntaje de felicidad
def grafico_barras_correlacion(df, variables, color, titulo, archivo, nombre_grupo):
    '''
    Barras horizontales con la correlación de cada variable con el puntaje.
    Imprime la variable más y menos asociada al puntaje (en valor absoluto).
    '''
    correlaciones = df[variables + [PUNTAJE]].corr()[PUNTAJE].drop(PUNTAJE).sort_values()

    fig, ax = plt.subplots(figsize=(8, 5))
    ax.barh(correlaciones.index, correlaciones.values, color=color)
    ax.set_title(titulo, fontsize=13, fontweight='bold')
    ax.set_xlabel("Correlación con el puntaje de felicidad")
    ax.axvline(0, linewidth=1)
    ax.grid(axis="x", alpha=0.3)
    for lado in ("top", "right", "left"):
        ax.spines[lado].set_visible(False)
    plt.tight_layout()
    fig.savefig(GRAF_DIR / f"resumen_correlacion_variables_{archivo}.png", dpi=300, bbox_inches="tight")
    plt.close(fig)

    fuerte = correlaciones.abs().idxmax()
    debil = correlaciones.abs().idxmin()
    print(f"\n→ {nombre_grupo}: la más asociada al puntaje es '{fuerte}' (r = {correlaciones[fuerte]:.2f}) "
          f"y la menos asociada es '{debil}' (r = {correlaciones[debil]:.2f}).")
```

Correlaciones de variables del WHR con el puntaje de felicidad:

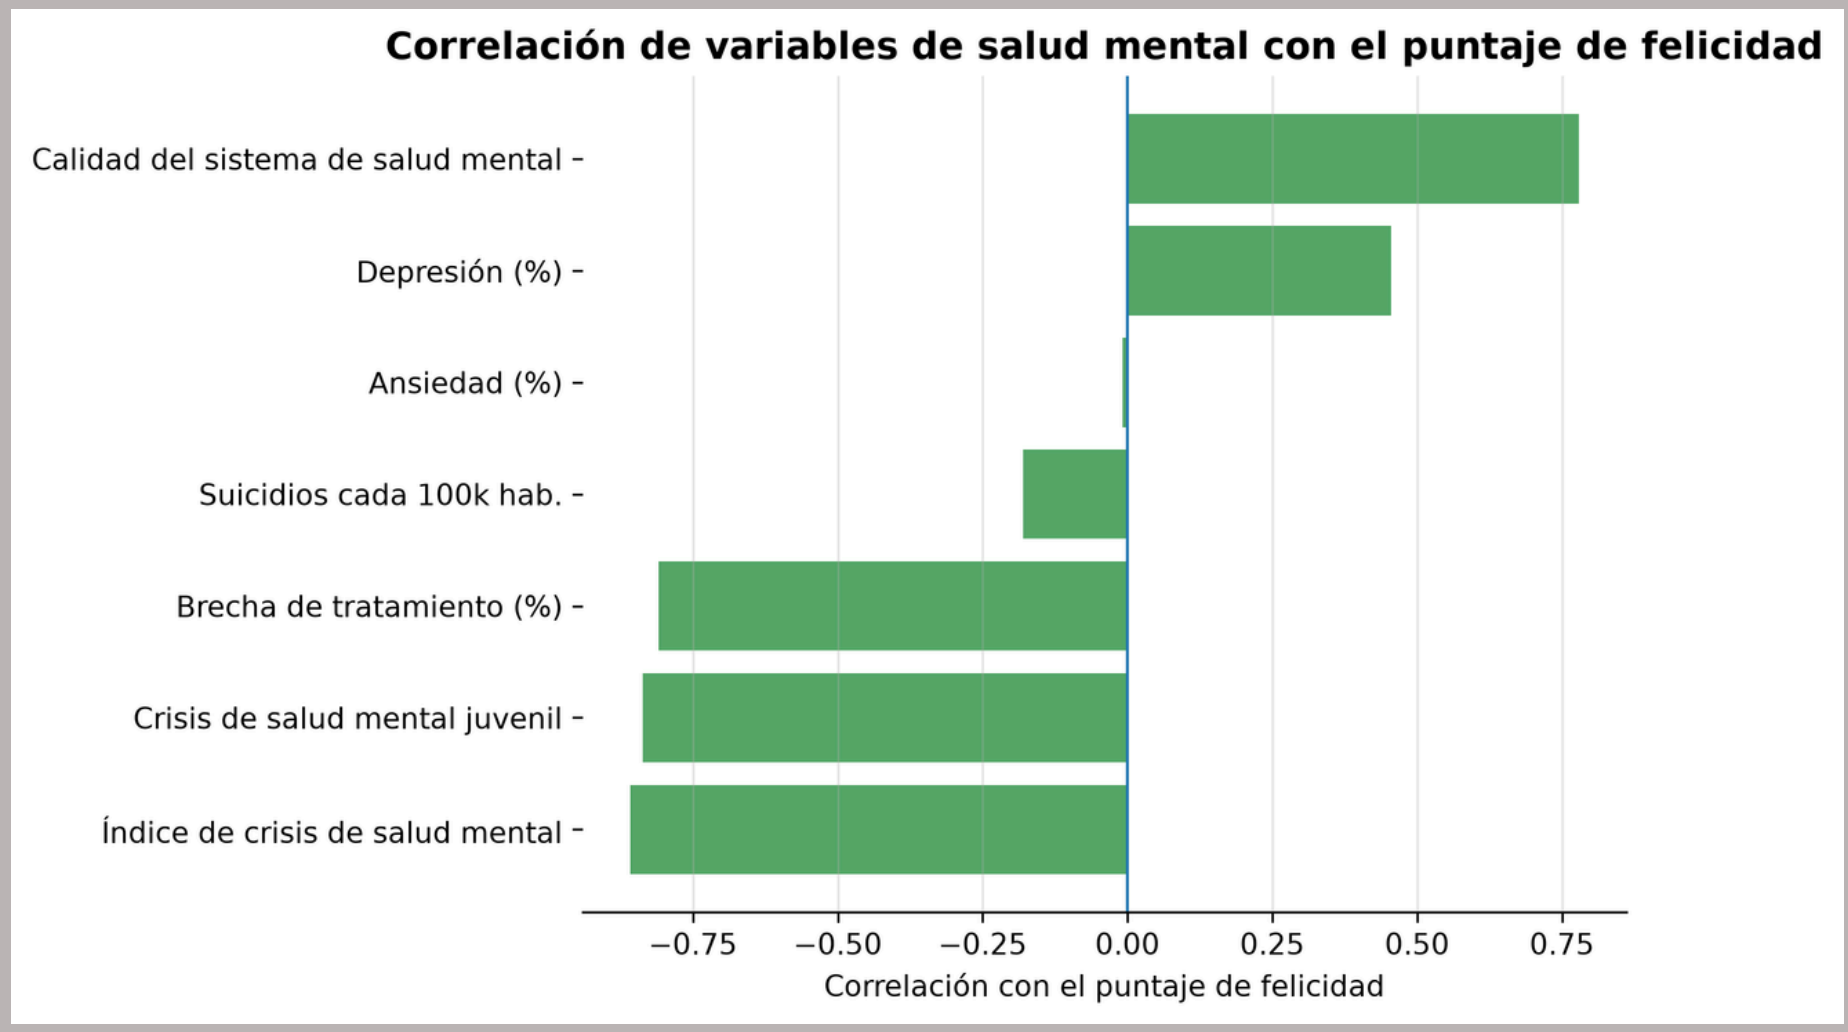
```
grafico_barras_correlacion(
    df_happiness_limpio, variables_whr, '#4C72B0',
    "Correlación de variables del World Happiness Report con el puntaje de felicidad",
    "world_happiness_report", "Variables del WHR")
```



Las variables del WHR tienen correlaciones muy altas con el puntaje (cerca de 0,9 o más), excepto generosidad (aprox 0,25).
==> Tiene sentido, porque son los criterios con los que se calcula el puntaje.

Correlaciones de variables de Salud Mental con el puntaje de felicidad:

```
grafico_barras_correlacion(
    df_final, variables_salud_mental, '#55A868',
    "Correlación de variables de salud mental con el puntaje de felicidad",
    "salud_mental", "Variables de salud mental")
```



Las variables de salud mental se comportan distinto, y se separan en tres grupos:

- **Correlación negativa fuerte:** índice de crisis, crisis juvenil y brecha de tratamiento (aprox -0,8). A más crisis y más gente sin tratamiento, menos felicidad.
- **Correlación positiva fuerte:** calidad del sistema de salud mental (aprox 0,8).
- **Correlación débil:** ansiedad (casi cero), suicidios (aprox -0,2) y depresión (aprox 0,45)

Lo que parece importar no es cuánta depresión o ansiedad hay, sino cómo responde el país (calidad del sistema y acceso a tratamiento).

2. **Análisis de las variables en los 10 países más y menos felices**

Utilidad: Muestra variables que más se diferencian entre los extremos del ranking y ayuda a elegir cuales incluir en el modelo

```python
# 3.2 PROMEDIOS DE LAS VARIABLES EN LOS 10 PAÍSES MÁS Y MENOS FELICES
variables_todas = variables_whr + variables_salud_mental
top10 = df_final.nlargest(10, PUNTAJE)
bottom10 = df_final.nsmallest(10, PUNTAJE)

comparacion = pd.DataFrame({
    "10 países con mayor felicidad": top10[variables_todas].mean(),
    "10 países con menor felicidad": bottom10[variables_todas].mean(),
})
print("\n\nPROMEDIO DE LAS VARIABLES EN LOS 10 PAÍSES MÁS Y MENOS FELICES:")
print(comparacion.round(2))
```

```
PROMEDIO DE LAS VARIABLES EN LOS 10 PAÍSES MÁS Y MENOS FELICES:
                                10 países con mayor felicidad  10 países con menor felicidad
PIB per cápita                                           1.76                           0.62
Apoyo social                                             1.51                           0.90
Esperanza de vida saludable                              0.92                           0.55
Libertad                                                 0.64                           0.36
Generosidad                                              0.21                           0.15
Percepción de corrupción                                 0.14                           0.06
Depresión (%)                                            4.83                           4.12
Ansiedad (%)                                             5.50                           5.96
Suicidios cada 100k hab.                                11.23                          19.67
Brecha de tratamiento (%)                               29.00                          90.50
Crisis de salud mental juvenil                           6.00                           9.00
Índice de crisis de salud mental                        45.50                          78.80
Calidad del sistema de salud mental                     69.47                           6.78
```

2. **Análisis de las variables en los 10 países más y menos felices**

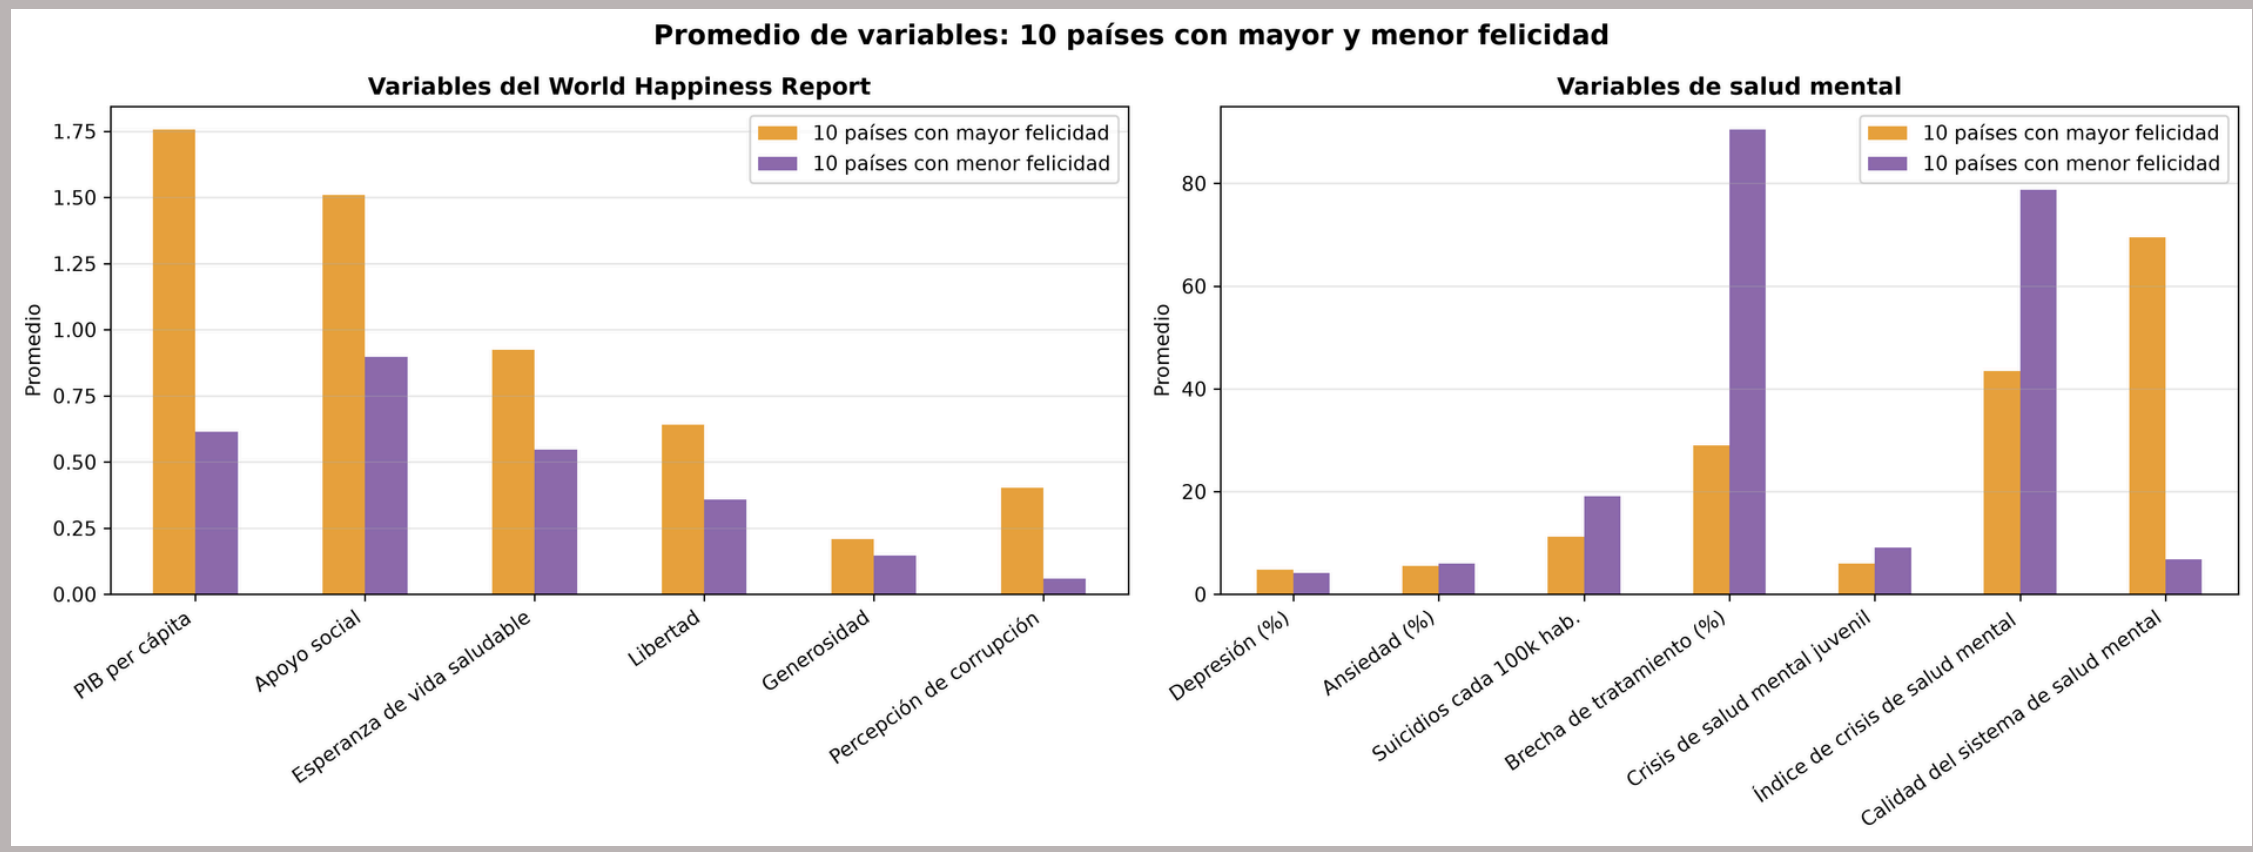
```python
# Dos gráficos porque las variables tienen rangos muy distintos
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 6))

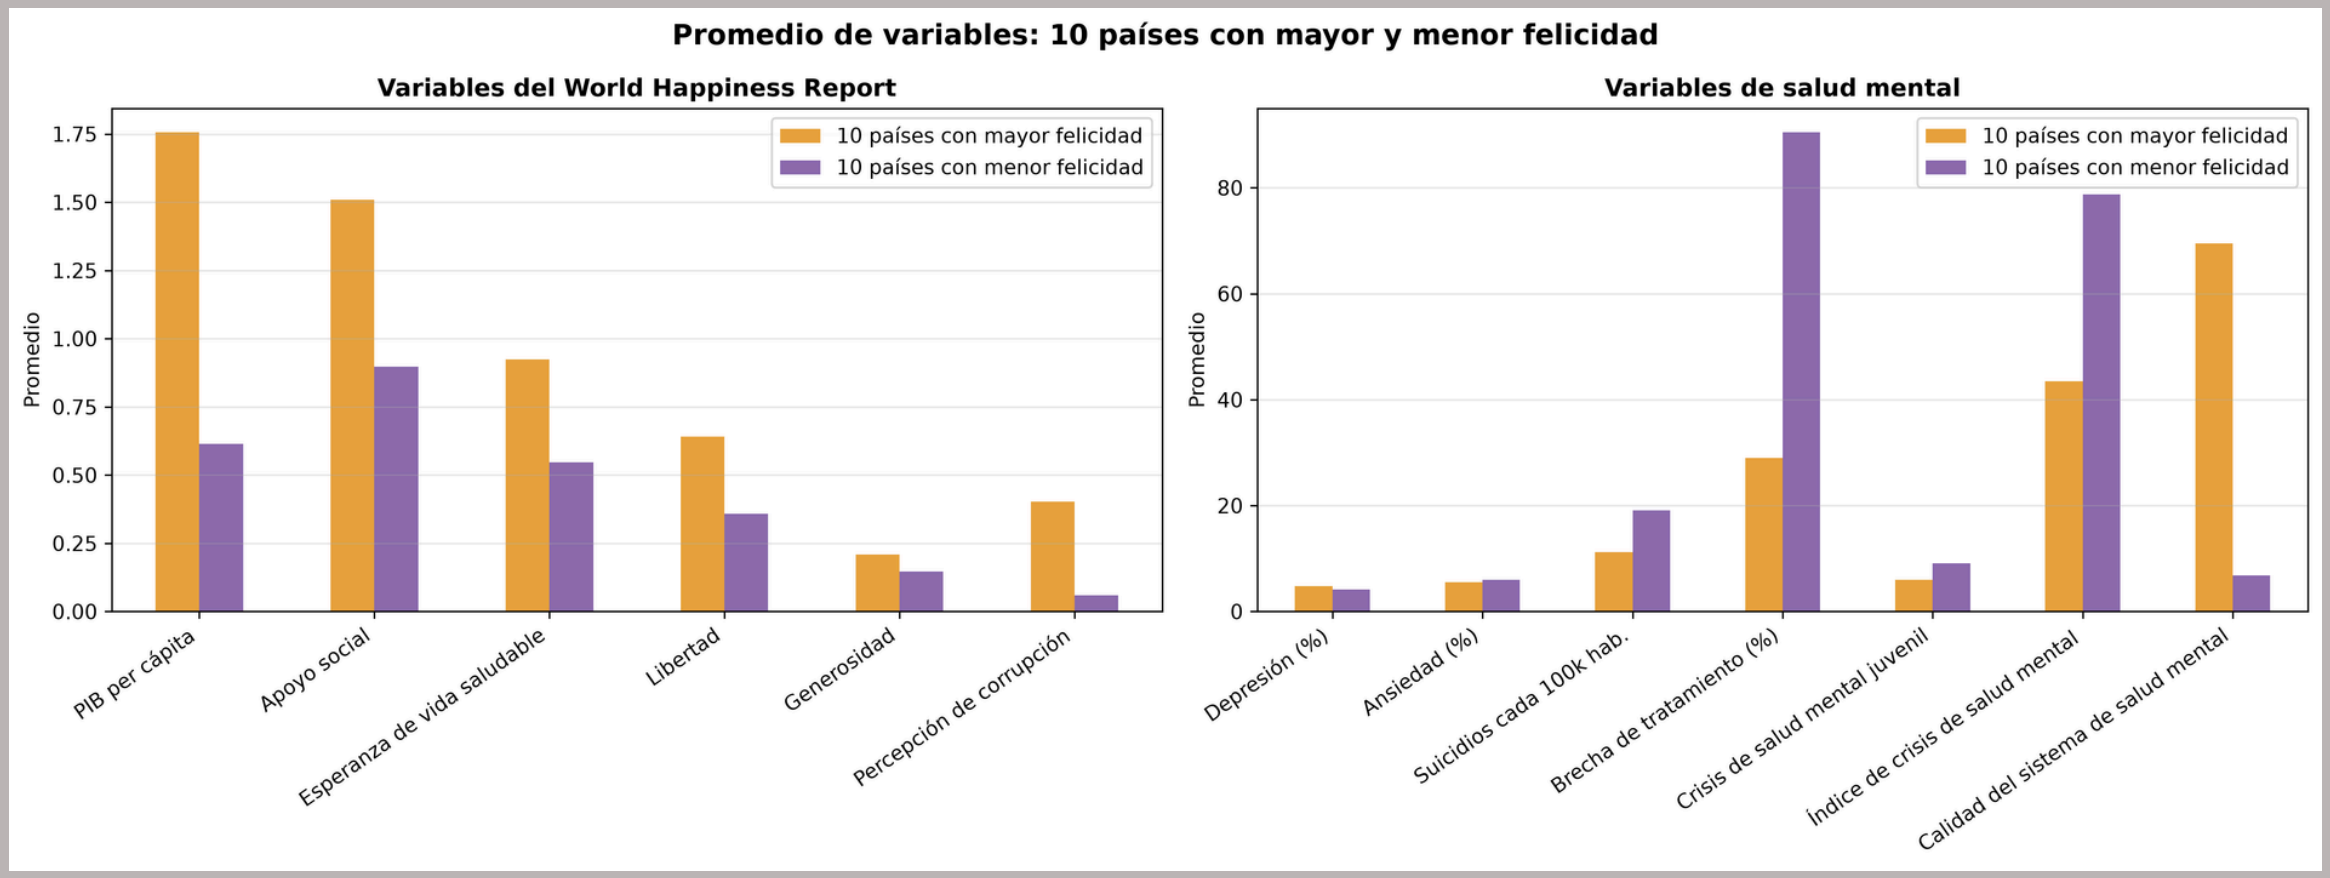
comparacion.loc[variables_whr].plot(kind="bar", ax=ax1, color=['#E8A33D', '#8C6BAE'])
ax1.set_title("Variables del World Happiness Report", fontsize=12, fontweight='bold')

comparacion.loc[variables_salud_mental].plot(kind="bar", ax=ax2, color=['#E8A33D', '#8C6BAE'])
ax2.set_title("Variables de salud mental", fontsize=12, fontweight='bold')

for ax in (ax1, ax2):
    ax.set_ylabel("Promedio")
    ax.grid(axis="y", alpha=0.3)
    ax.tick_params(axis='x', rotation=35)
    for label in ax.get_xticklabels():
        label.set_ha("right")

plt.suptitle("Promedio de variables: 10 países con mayor y menor felicidad", fontsize=14, fontweight='bold')
plt.tight_layout()
fig.savefig(GRAF_DIR / "top10_vs_bottom10_felicidad.png", dpi=300, bbox_inches="tight")
plt.close(fig)
```





World Happiness Report:

- Las 6 variables son más altas en los países más felices.
- Mayores diferencias: PIB per cápita (1,76 vs 0,62) y percepción de corrupción (0,40 vs 0,06).
- Generosidad es la que menos separa a los grupos.

En salud mental:

- Depresión y ansiedad son casi iguales en los dos grupos (entre 4% y 6%)
- Lo que sí separa a los grupos es la respuesta del sistema: la brecha de tratamiento (pasa de 29% a 90%) y la calidad del sistema de salud mental de 69 a 7.

Restricción de este análisis:
Se analizan solo 20 de 140 países y se deja afuera a la mayoría. Elegir países según el puntaje de felicidad exagera las diferencias entre grupos y no tiene en cuenta otros factores como la región o el nivel de ingreso, así que no se puede separar el efecto de cada variable.

3. **Análisis por región**

Utilidad: Crear una nueva columna que puede aportar a la regresión lineal

```
df_final[REGION] = df_final[PAIS].apply(obtener_region)
print("\n\nPaíses sin región:", df_final.loc[df_final[REGION].isna(), PAIS].tolist())
df_final = df_final.dropna(subset=[REGION])

# Promedios por región
vars_region = [PUNTAJE, "Depresión (%)", "Ansiedad (%)", "Índice de crisis de salud mental"]
promedios = df_final.groupby(REGION)[vars_region].mean().round(2)
print("\nPromedios por región:")
print(promedios)
print("\nPaíses por región:")
print(df_final[REGION].value_counts())

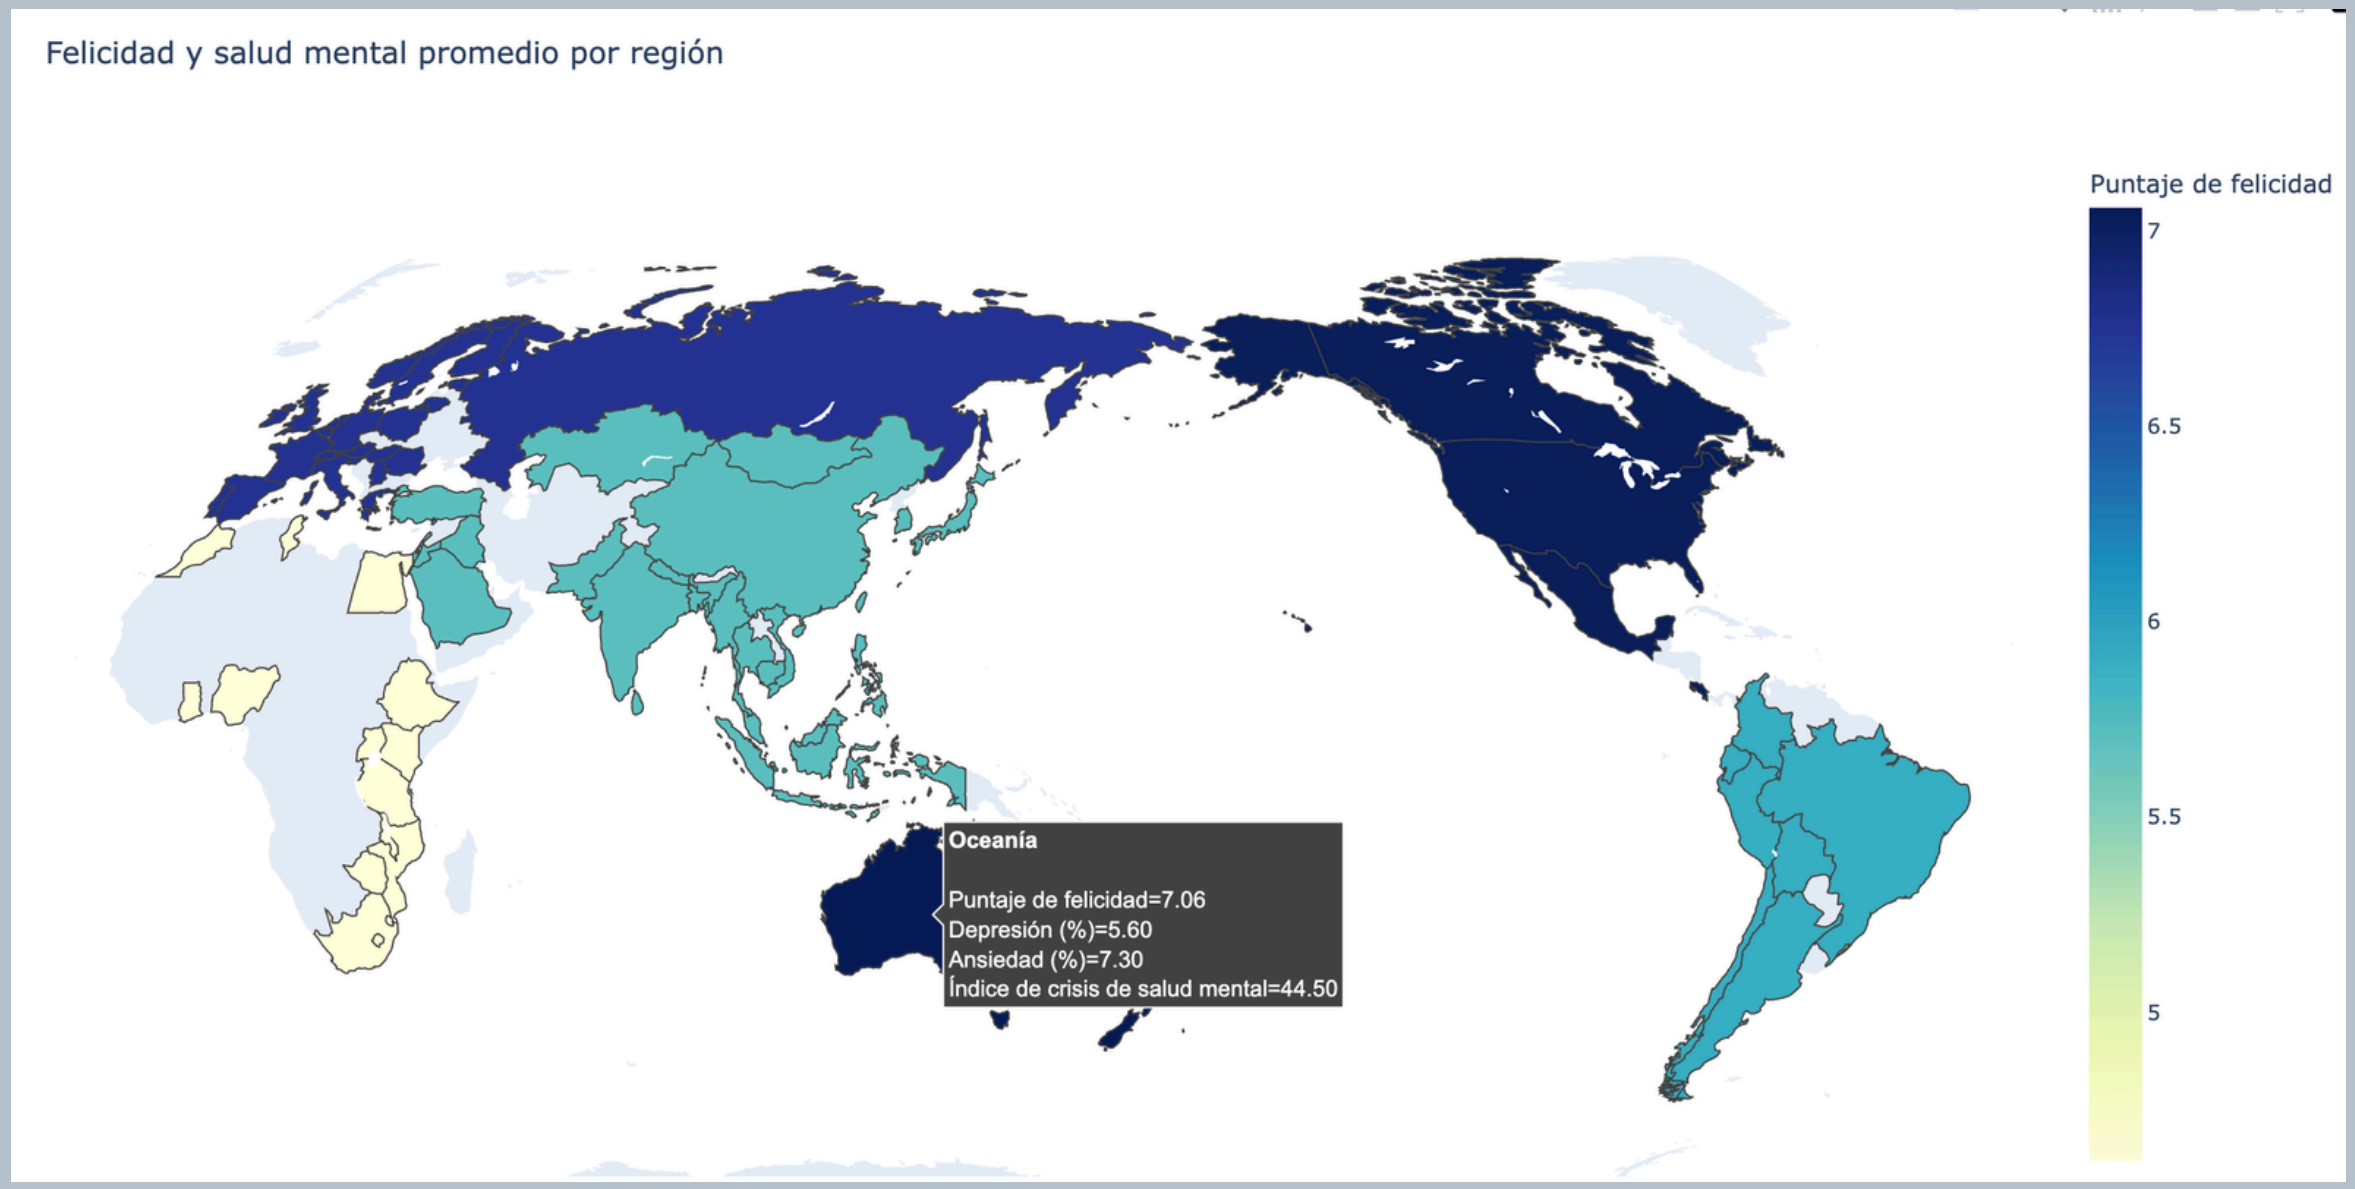
# Cada país toma los valores promedio de su región
mapa_df = df_final[[PAIS, REGION]].merge(promedios, on=REGION)
```

```
Promedios por región:
                Puntaje de felicidad  Depresión (%)  Ansiedad (%)  Índice de crisis de salud mental
Región
América del Norte                7.04           5.03          6.62                             52.00
América del Sur                  5.90           4.84          6.84                             63.29
Asia                             5.70           3.99          5.45                             59.52
Europa                           6.76           5.01          5.45                             44.88
Oceanía                          7.06           5.60          7.30                             44.50
África                           4.62           3.97          5.52                             77.33
```

```
Países por región:
Región
Asia                25
Europa              24
África              15
América del Sur      7
América del Norte    4
Oceanía              2
Name: count, dtype: int64
```

→ La región más feliz en promedio es Oceanía (7.06) y la menos feliz es África (4.62).

Mapa interactivo con los valores por región



→ **Mayor fortaleza y mayor debilidad de cada región:**

América del Norte: fortaleza = Libertad; debilidad = Ansiedad (%)

América del Sur: fortaleza = Suicidios cada 100k hab.; debilidad = Ansiedad (%)

Asia: fortaleza = Depresión (%); debilidad = Calidad del sistema de salud mental

Europa: fortaleza = Calidad del sistema de salud mental; debilidad = Depresión (%)

Oceanía: fortaleza = Generosidad; debilidad = Depresión (%)

África: fortaleza = Depresión (%); debilidad = Esperanza de vida saludable

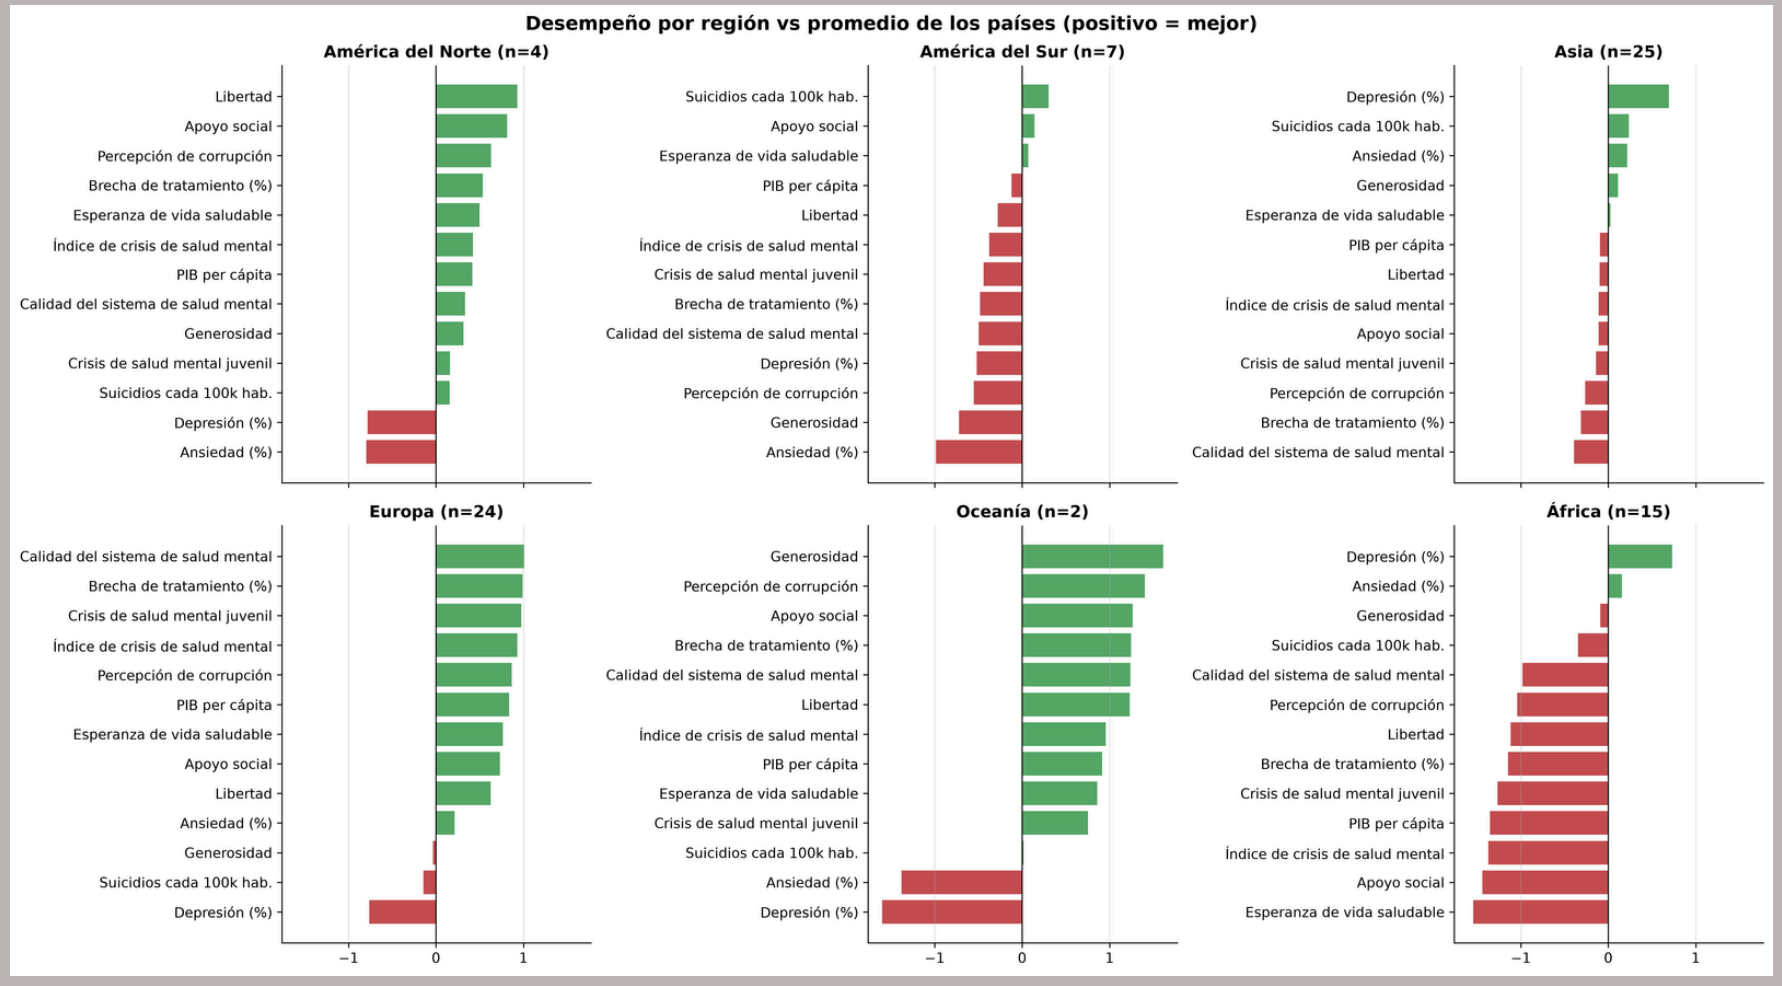
4. **Desempeño por región**

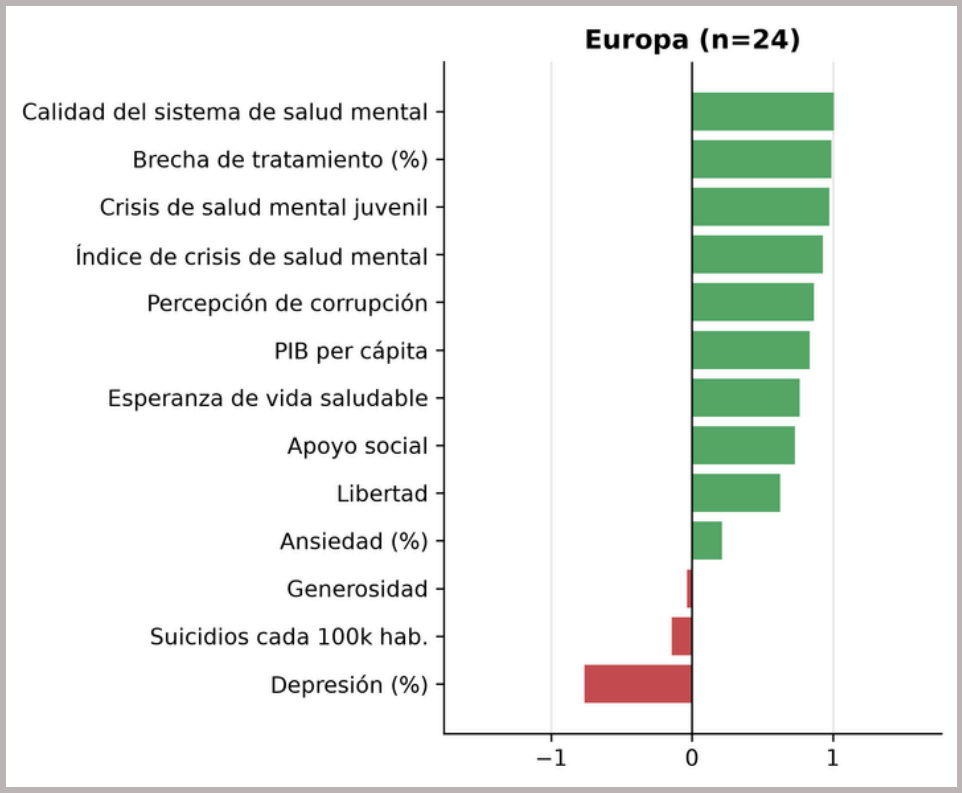
(puntaje z: cuánto se aleja cada región del promedio de los países)

```
# Variables en las que un valor más alto es PEOR. Se invierten para que positivo siempre signifique "mejor que el promedio".
mas_alto_es_peor = ["Depresión (%)", "Ansiedad (%)", "Suicidios cada 100k hab.",
                    "Brecha de tratamiento (%)", "Crisis de salud mental juvenil",
                    "Índice de crisis de salud mental"]

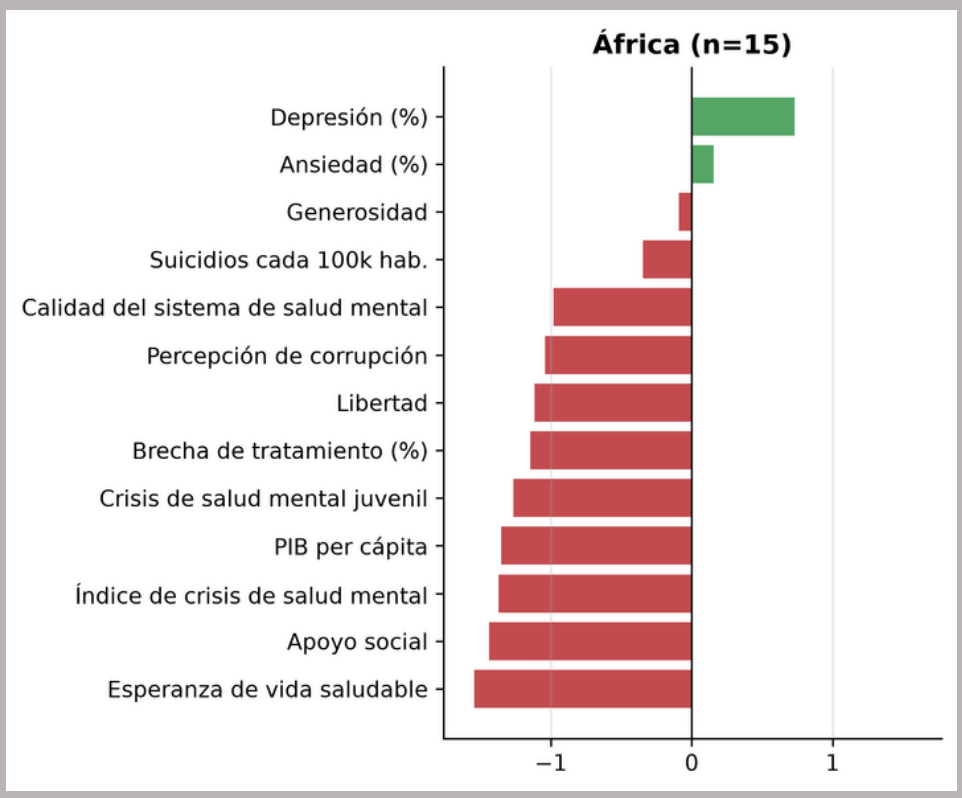
# z-score de cada variable respecto a todos los países
z = (df_final[variables_todas] - df_final[variables_todas].mean()) / df_final[variables_todas].std()
z[mas_alto_es_peor] = -z[mas_alto_es_peor]
z[REGION] = df_final[REGION]
z_region = z.groupby(REGION)[variables_todas].mean()

# Un gráfico por región
regiones = z_region.index.tolist()
fig, axes = plt.subplots(2, 3, figsize=(18, 10), sharex=True)
```

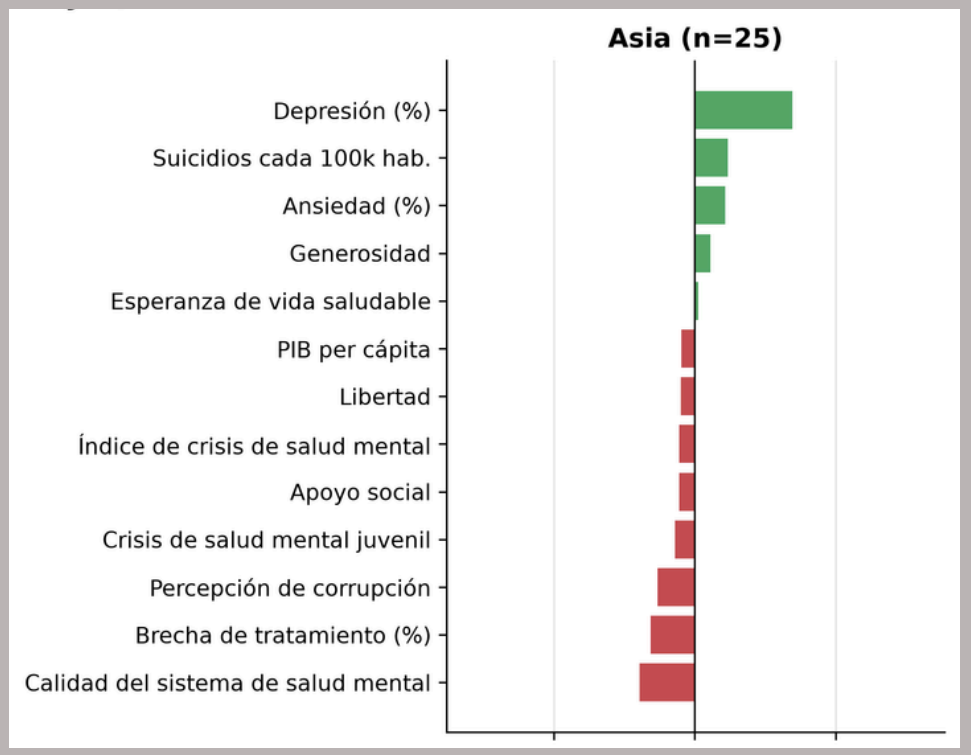




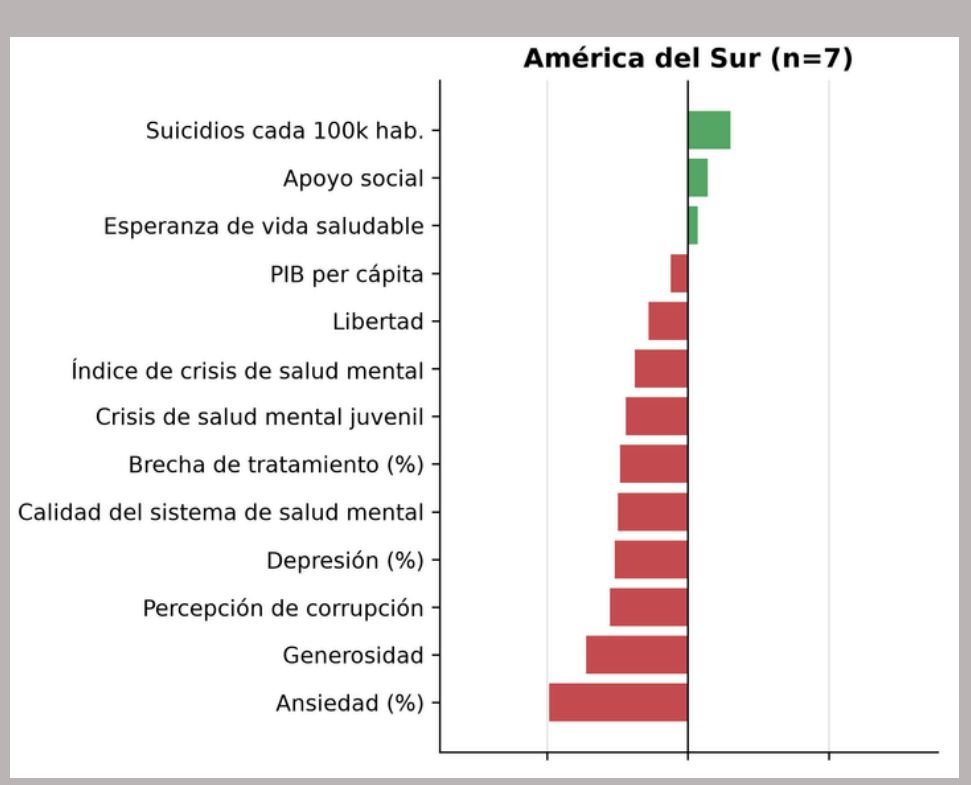
- Europa está por encima del promedio en casi todo, con buenos puntajes de SM inculso mejores que el PBI.



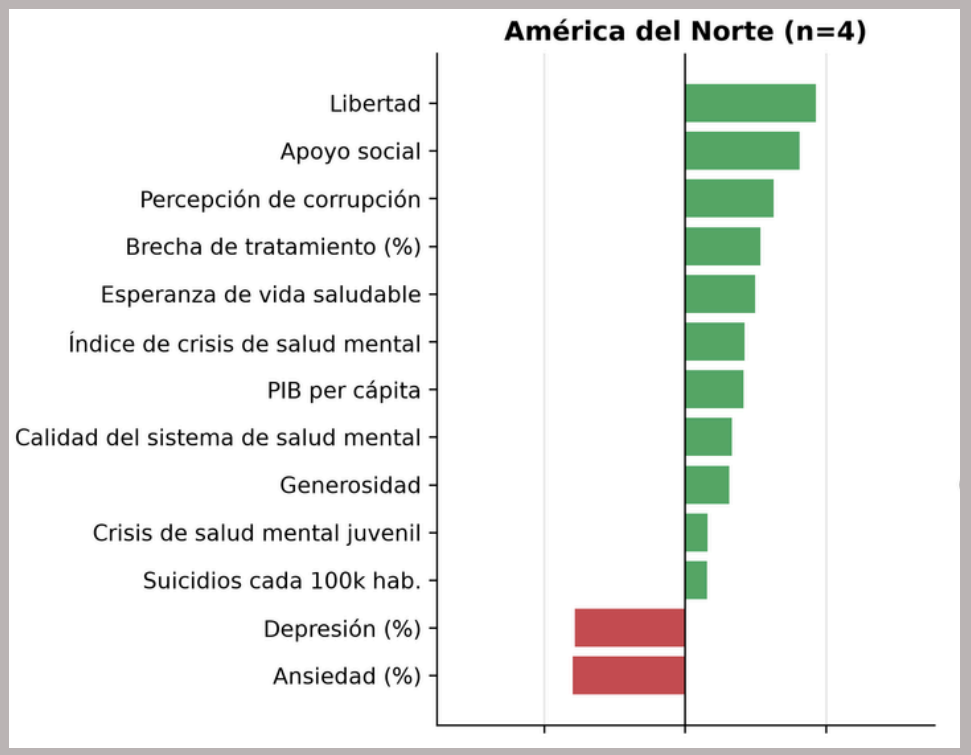
- África es el peor caso, está por debajo del promedio en casi todas las variables.

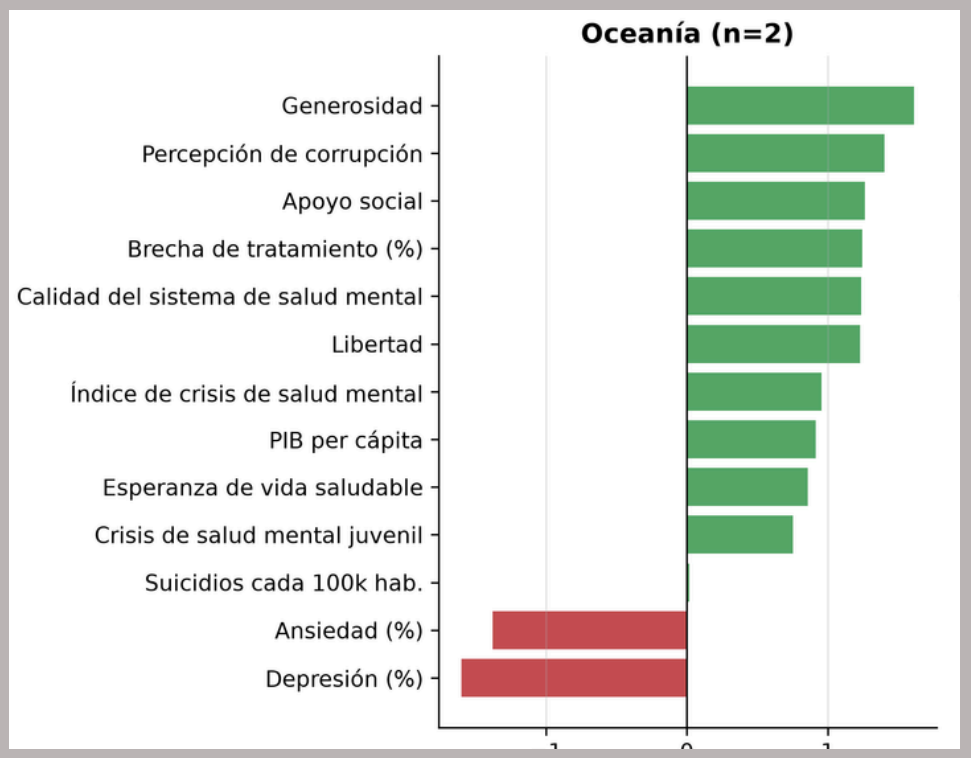


- Asia queda cerca del promedio en casi todo



- América del Sur queda algo por debajo del promedio.





- América del Norte y Oceanía tienen muy buen desempeño general, pero son pocos países.

Modelos



Armamos modelos de **regresión lineal** que estiman el puntaje de felicidad de un país a partir de otras variables, con una fórmula del tipo: **$Y = a + b1 \cdot x1 + b2 \cdot x2 + \ldots$**

Para comparar los modelos usamos el R^2:

- R^2 = 1 - (error del modelo / variación total del puntaje)
- R^2 = 0 -> el modelo no mejora a predecir el puntaje de felicidad
- R^2 = 1 -> el modelo predice perfecto

Problema: el R^2 sube siempre que agregamos una variable
==> Por eso también miramos el **R^2 AJUSTADO**, que penaliza las variables que no suman y sube solo si las variables nuevas aportan

Un R^2 alto muestra que las variables están asociadas a la felicidad, no que la causen.

1. Preparamos los datos para los modelos y definimos el “Y” que queremos explicar

```
columnas_para_modelos = [PAIS, PUNTAJE, REGION] + variables_whr + variables_salud_mental
datos_modelos = df_final[columnas_para_modelos].copy() # tabla a parte para los modelos

y = datos_modelos[PUNTAJE] # Y = variable que queremos explicar
# la definimos arriba porque todos los modelos explican la misma "y"
```

2. Función que calcula el R^2 ajustado (penaliza las variables que no aportan al modelo)

```
def r2_ajustado(r2, n, p):
    '''
    (n = cantidad de países, p = cantidad de variables)
    Calcula el R² ajustado: corrige el R² según cuántas variables usa el modelo.
    Solo sube si la variable nueva realmente aporta.
    '''
    return 1 - (1 - r2) * (n - 1) / (n - p - 1)
# en la función crear_modelo llamo a r2_ajustado y le paso:
# - r2
# - len(y): la cantidad de países (n), porque y tiene un valor por país
# - X.shape[1]: la cantidad de columnas de X (variables del modelo p)
```

3. Función para crear un modelo según una lista de variables X

```
def crear_modelo(X):
    '''
    Arma una regresión lineal que explica el puntaje de felicidad con las variables X.
    Devuelve el modelo (con su fórmula), su R² y su R² ajustado.
    '''
    modelo = LinearRegression() # crea un modelo de regresión
    modelo.fit(X, y) # incorpora las variables X ingresadas al modelo
    r2 = modelo.score(X, y) # calcula R²
    return modelo, r2, r2_ajustado(r2, len(y), X.shape[1])
```

Tabla 1: Región, PBI e Indice de crisis de salud mental
Que variables ayudan a explicar la felicidad?

1. Seleccionamos los mismos 77 paises

2. Convertimos región a numeros

```
# Primero tenemos que pasar la región a numeros ya que la regresión solo trabaja con números y la región es texto.
regiones_0_1 = pd.get_dummies(datos_modelos[REGION], dtype=float).drop(columns="Europa")
# Creamos una columna por región, que vale 1 si el país es de esa región y 0 si no.
# Europa queda como región base (es la de más países)
```

3. Armamos 3 modelos con distintas combinaciones de variables y calculamos su R^2
Combinaciones: PBI, PBI + Región, PBI + Región + Indice de crisis de Salud Mental

```
# Armamos las variables (X) de cada modelo
X_modelo1 = regiones_0_1.copy()

X_modelo2 = X_modelo1.copy()
X_modelo2["PIB per cápita"] = datos_modelos["PIB per cápita"] # sumo al 1 la columna de PBI

X_modelo3 = X_modelo2.copy()
X_modelo3["Índice de crisis de salud mental"] = datos_modelos["Índice de crisis de salud mental"] # sumo al 2 indice de crisis de SM

# Creamos los 3 modelos y guardamos su R² y R² ajustado
modelo1, r2_1, r2a_1 = crear_modelo(X_modelo1)
modelo2, r2_2, r2a_2 = crear_modelo(X_modelo2)
modelo3, r2_3, r2a_3 = crear_modelo(X_modelo3)

# Calculamos cuánto aporta cada bloque nuevo (con el R² ajustado)
aporte_pib = r2a_2 - r2a_1   # lo que suma el PIB a la región
aporte_sm = r2a_3 - r2a_2    # lo que suma la salud mental a la región y el PIB
```

Tabla 1:
Cuanto aporta cada variable al modelo?
Que combinación de variables vamos a usar para el modelo?

TABLA 1: REGIÓN, PIB Y SALUD MENTAL

Modelo	Variables	R^2	R^2 ajustado	Aporte adicional
Modelo 1	Región	0.651	0.626	NaN
Modelo 2	Región + PIB	0.810	0.794	0.168
Modelo 3	Región + PIB + salud mental	0.812	0.793	−0.001



- El PIB aumentó el R^2 en 15,9 puntos porcentuales. El índice de crisis de salud mental agregó solo 0,2 puntos adicionales.

- La pequeña mejora del R^2 no alcanza para compensar la incorporación de otra variable y disminuye.

Tabla 2 - Que indicadres explican mejor la felicidad?

- Quisimos analizar más específicamente los indicadores de salud mental.
- Codigo para ordenar los indicadores

```
tabla_2 = pd.DataFrame({
    "Modelo": ["Modelo 1", "Modelo 2", "Modelo 3", "Modelo 4"],
    "Variables": ["Crisis juvenil",
                  "+ Brecha de tratamiento",
                  "+ Calidad del sistema",
                  "+ Depresión"],
    "R²": [r2_sm1, r2_sm2, r2_sm3, r2_sm4],
    "R² ajustado": [r2a_sm1, r2a_sm2, r2a_sm3, r2a_sm4],
    "Aporte adicional": [None, r2a_sm2 - r2a_sm1, r2a_sm3 - r2a_sm2, r2a_sm4 - r2a_sm3],
})

print("\n\nTABLA 2: REGRESIONES CON VARIABLES DE SALUD MENTAL")
print(tabla_2.round(3).to_string(index=False))
```

- ¿Qué hicimos?

- Seleccionamos cuatro indicadores de salud mental.
- Analizamos si estaban muy correlacionados entre sí.
- Calculamos el R^2 de cada uno por separado.
- Los ordenamos de mayor a menor R^2 para construir las regresiones.

Tabla 2 - Construimos 4 regresiones

```
# Primero vemos cuánto explica cada variable sola.
# Una regresión con cada variable de SM por separado y su R². Así sabemos cuál explica más por sí misma.
print("\n\nR² DE CADA VARIABLE DE SALUD MENTAL POR SEPARADO:")
for variable in variables_salud + ["Índice de crisis de salud mental"]:
    modelo, r2, r2a = crear_modelo(datos_modelos[[variable]])
    print(f"{variable}: R² = {r2:.3f}") # imprime solo 3 decimales

# Empezamos por la variable con mayor correlación con felicidad y vamos agregando las demás en orden
# Modelo 1: crisis juvenil
modelo_sm1, r2_sm1, r2a_sm1 = crear_modelo(datos_modelos[variables_salud[:1]])

# Modelo 2: crisis juvenil + brecha de tratamiento
modelo_sm2, r2_sm2, r2a_sm2 = crear_modelo(datos_modelos[variables_salud[:2]])

# Modelo 3: crisis juvenil + brecha + calidad del sistema
modelo_sm3, r2_sm3, r2a_sm3 = crear_modelo(datos_modelos[variables_salud[:3]])

# Modelo 4: crisis juvenil + brecha + calidad del sistema + depresión
modelo_sm4, r2_sm4, r2a_sm4 = crear_modelo(datos_modelos[variables_salud[:4]])
# [:4] toma las 4 primeras variables de la lista
```

El bucle for crea cuatro modelos.

- R1: crisis juvenil
- R2: + brecha de tratamiento
- R3: + calidad del sistema
- R4: + depresión
- Calculamos R^2 y R^2 ajustado en cada caso.

Tabla 2 - Que combinación de variables de Salud Mental vamos a usar para el modelo?

TABLA 2: REGRESIONES CON VARIABLES DE SALUD MENTAL

Modelo	Variables	R^2	R^2 ajustado	Aporte adicional
Modelo 1	Crisis juvenil	0.700	0.696	NaN
Modelo 2	+ Brecha de tratamiento	0.705	0.697	0.001
Modelo 3	+ Calidad del sistema	0.705	0.693	−0.004
Modelo 4	+ Depresión	0.719	0.704	0.010

¿Por qué elegimos R4?

R4 obtiene el mayor R^2 ajustado: 70,4%.

El R^2 ajustado tiene en cuenta cuántas variables incorporamos.

Por eso no elegimos solamente el modelo con más variables, sino el que mejor resultado ajustado consigue.

Modelo final

La región aporta información?

```
# 4.5 MODELO FINAL: SALUD MENTAL + REGIÓN

# Armamos las variables del modelo (salud mental + columnas 0/1 de región)
X_final = datos_modelos[vars_salud_final].join(regiones_0_1)
# Creamos el modelo
modelo_final, r2_final, r2a_final = crear_modelo(X_final)
```

```
MODELO FINAL (SALUD MENTAL + REGIÓN):
R² = 0.798 | R² ajustado = 0.771 | 77 países
Solo salud mental (Tabla 2): R² ajustado = 0.704
→ Sumar la región aporta +0.067 de R² ajustado.
```

Resultados y conclusión

R4 (solo salud mental)

R^2 ajustado: 70,4%

R4 + región

R^2: 79,8%

R^2 ajustado: 77,1%

La región aporta +6,7 puntos de R^2 ajustado.

El modelo final no incluye PIB.

Modelo final

Coeficientes (b de la fórmula)

```python
# Coeficientes del modelo (los "b" de la fórmula)
coeficientes = pd.Series(modelo_final.coef_, index=X_final.columns, name="Coeficiente")
print("\nCoeficientes:")
print(coeficientes.round(3).to_string())
```

```
Coeficientes:
Crisis de salud mental juvenil        -0.560
Brecha de tratamiento (%)              0.010
Calidad del sistema de salud mental    0.008
Depresión (%)                         -0.043
América del Norte                      0.883
América del Sur                        0.048
Asia                                  -0.374
Oceanía                                0.514
África                                -0.769
Cada coeficiente indica cuánto cambia el puntaje predicho si esa variable sube 1 unidad
y las demás quedan iguales. En las regiones: diferencia de felicidad respecto a Europa.
```

Armamos la formula de regresión lineal del tipo **Y = a + bx1 + bx2 + ...**

```python
# Fórmula de la regresión: Y = a + b1·x1 + b2·x2 + ...
formula = f"Felicidad = {modelo_final.intercept_:.2f}"
for variable, b in zip(X_final.columns, modelo_final.coef_):
    signo = "+" if b >= 0 else "-"
    formula += f"\n   {signo} {abs(b):.3f} · {variable}"
```

```
FÓRMULA DEL MODELO FINAL:
Felicidad = 9.61
   - 0.560 · Crisis de salud mental juvenil
   + 0.010 · Brecha de tratamiento (%)
   + 0.008 · Calidad del sistema de salud mental
   - 0.043 · Depresión (%)
   + 0.883 · América del Norte
   + 0.048 · América del Sur
   - 0.374 · Asia
   + 0.514 · Oceanía
   - 0.769 · África
(Región: vale 1 si el país es de esa región y 0 si no. Europa es la base.)
```

Gráfico del modelo final

1. Calcular el puntaje predicho de cada país y el error

```
datos_modelos["Puntaje predicho"] = modelo_final.predict(X_final)
datos_modelos["Error"] = datos_modelos[PUNTAJE] - datos_modelos["Puntaje predicho"]
```

2. Gráfico con un punto por país y un color por región

```
fig, ax = plt.subplots(figsize=(9, 7))

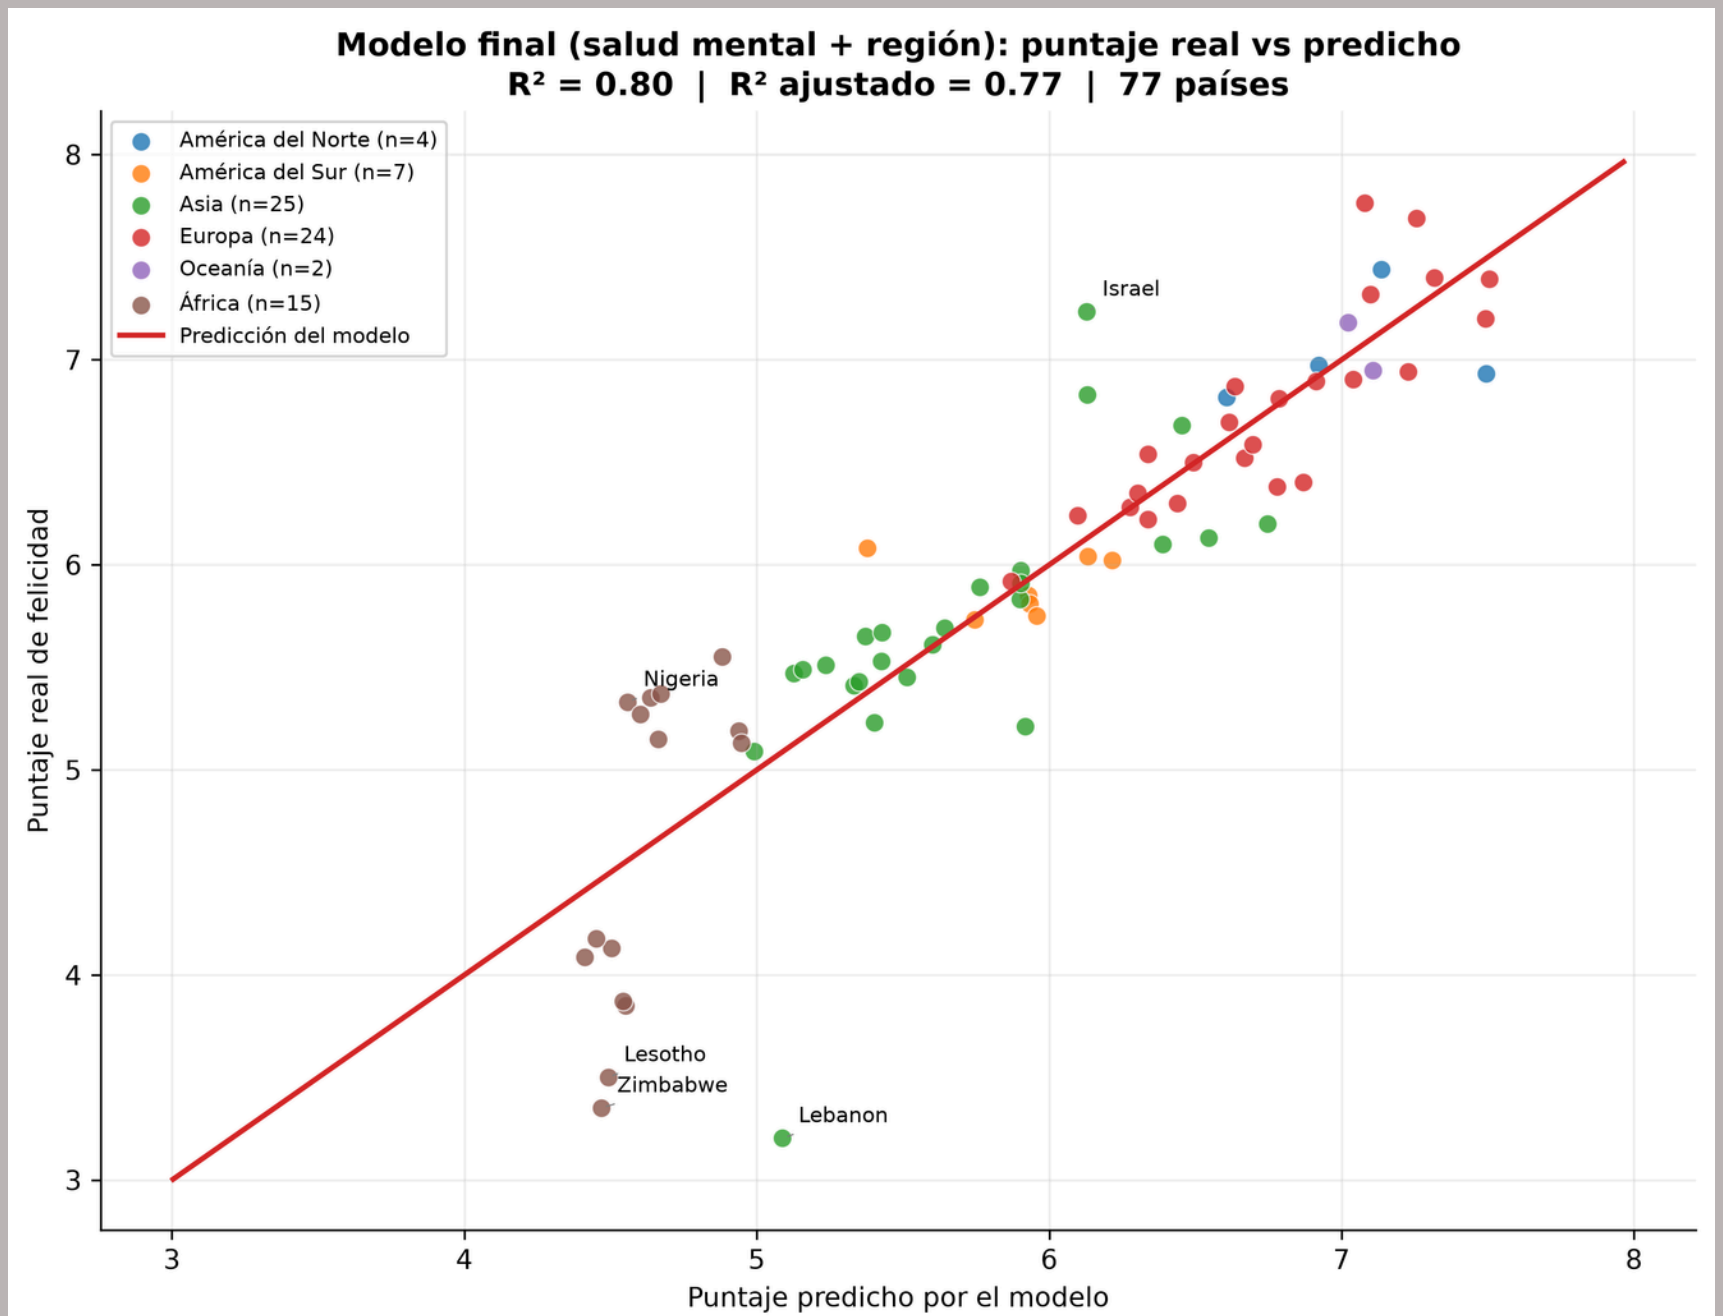
# Un color por región
for region, paises_region in datos_modelos.groupby(REGION):
    ax.scatter(paises_region["Puntaje predicho"], paises_region[PUNTAJE], alpha=0.8,
               edgecolor='white', linewidth=0.5, s=50,
               label=f"{region} (n={len(paises_region)})")
```

3. Creamos una recta roja con la predicción del modelo

```
# Línea de predicción del modelo
minimo = min(datos_modelos[PUNTAJE].min(), datos_modelos["Puntaje predicho"].min()) - 0.2
maximo = max(datos_modelos[PUNTAJE].max(), datos_modelos["Puntaje predicho"].max()) + 0.2
ax.plot([minimo, maximo], [minimo, maximo], color='#D62728', linewidth=2, label="Predicción del modelo")
```

4. Identifica los puntos de los 5 países con mayor error del modelo

```
# Etiquetamos los 5 países más alejados de lo que predice el modelo (mayor error, sin importar el signo)
paises_lejanos = datos_modelos.loc[datos_modelos["Error"].abs().nlargest(5).index]
for indice, pais in paises_lejanos.iterrows():
    ax.annotate(pais[PAIS], (pais["Puntaje predicho"], pais[PUNTAJE]),
                xytext=(6, 6), textcoords='offset points', fontsize=8,
                arrowprops=dict(arrowstyle='-', color='gray', lw=0.5))
```



Formula final ==>

Y = a + bx1 + bx2 + ...

```
Felicidad = 9.61
   − 0.560 · Crisis de salud mental juvenil
   + 0.010 · Brecha de tratamiento (%)
   + 0.008 · Calidad del sistema de salud mental
   − 0.043 · Depresión (%)
   + 0.883 · América del Norte
   + 0.048 · América del Sur
   − 0.374 · Asia
   + 0.514 · Oceanía
   − 0.769 · África
(Región: 1 si el país es de esa región, 0 si no. Base: Europa)
```

→ R^2: El modelo final explica el 80% de las diferencias de felicidad entre países usando solo salud mental y región, sin variables del WHR.